

Web aplikacije (WA - 199769)



Nositelj: doc. dr. sc. Nikola Tanković

Asistent: Luka Blašković, mag. inf.

Ustanova: Sveučilište Jurja Dobrile u Puli, Fakultet informatike u Puli



Fakultet informatike u Puli

(5) MongoDB baza podataka

U prethodnom poglavlju upoznali smo se s načinima pohrane podataka na poslužitelju u datoteke te objasnili zašto takav pristup postaje nepraktičan kod većih količina podataka i podataka kojima korisnici aplikacije izravno pristupaju. MongoDB je popularna nerelacijska (noSQL) baza podataka koja se temelji na dokumentno orijentiranom modelu pohrane. Za razliku od tradicionalnih relacijskih baza podataka koje koriste tablice i retke, MongoDB organizira podatke u zbirke (kolekcije) i dokumente. Podaci su pritom strukturirani u formatu sličnom JSON-u, što omogućuje fleksniju, pregledniju i intuitivniju organizaciju.



U nastavku ćemo naučiti kako izraditi MongoDB Atlas cluster u Cloudu, kako se na njega povezati putem Express poslužitelja te kako provoditi osnovne CRUD operacije nad podacima, kao i složenije agregacijske upite. Iako je skripta opsežna, za početak je ključno usvojiti temeljne koncepte i osnovne načine rada s MongoDB bazom podataka. Kasnije vam skripta može poslužiti kao praktična referenca i svojevrсна dokumentacija za daljnji rad s MongoDB bazom podataka.

 Posljednje ažurirano: 12.9.2026.

Sadržaj

- [Web aplikacije \(WA - 199769\)](#)
- [\(5\) MongoDB baza podataka](#)
 - [Sadržaj](#)
- [1. MongoDB](#)
 - [1.1 MongoDB Atlas](#)
- [2. Povezivanje na cluster u MongoDB Atlasu](#)

- 2.1 Priprema Express poslužitelja
- 2.2 MongoDB Connection string
- 2.3 `db.js`
- 2.4 Varijable okoline - `dotenv` modul
- 3. CRUD operacije na MongoDB bazi podataka
 - 3.1 GET operacija
 - Mongo metoda: `collection().find()`
 - 3.1.1 GET `/pizze`
 - 3.1.2 GET `/pizze/:naziv`
 - MongoDB indeksi (eng. Indexes)
 - Mongo metoda: `collection().findOne()`
 - 3.2 POST operacija
 - 3.2.1 POST `/pizze`
 - Mongo metoda: `collection().insertOne()`
 - 3.2.2 POST `/narudzbe`
 - Ponavljanje: Validacija zahtjeva na poslužitelju
 - 3.3 PUT i PATCH operacije
 - 3.3.1 PATCH `/pizze/:naziv`
 - Mongo metoda: `collection().updateOne()`
 - MongoDB Update operatori
 - 3.3.2 PATCH `/narudzbe/:id`
 - 3.3.3 PUT `/pizze`
 - Mongo metoda: `collection().insertMany()`
 - 3.4 DELETE operacija
 - 3.4.1 DELETE `/pizze/:naziv`
 - Mongo metoda: `collection().deleteOne()`
 - Mongo metoda: `collection().deleteMany()`
- 4. Agregacija podataka
 - 4.1 Filtriranje podataka
 - 4.1.1 GET `/pizze?query`
 - 4.2 Ažuriranje svih podataka gdje je uvjet zadovoljen
 - Mongo metoda: `collection().updateMany()`
 - 4.3 Sortiranje podataka
 - 4.3.1 GET `/pizze?sort`
 - 4.4 Složena agregacija podataka metodom `aggregate()`
- 5. MongoDB - TL;DR
 - 5.1 Spajanje na bazu podataka
 - 5.2 CRUD operacije
 - 5.3 MongoDB operatori
 - 5.3.1 Operatori ažuriranja (eng. Update operators)
 - 5.3.2 Operatori usporedbe (eng. Comparison operators)
 - 5.3.3 Logički operatori (eng. Logical operators)
- Samostalni zadatak za Vježbu 5

1. MongoDB

MongoDB je dokumentno-orijentirana (*eng. document-oriented*) nerelacijska baza podataka koja se koristi za pohranu podataka u formatu sličnom JSON-u. MongoDB razvija tvrtka MongoDB Inc. i dostupna je kao [source-available](#) softver. MongoDB je popularna baza podataka zbog svoje skalabilnosti, fleksibilnosti i jednostavnosti korištenja.

Općenito, baze podataka možemo podijeliti na relacijske i nerelacijske (NoSQL).

1. **Relacijske baze podataka** (*eng. Relational database*) pohranjuju podatke u tabličnom formatu koristeći **redove** i **stupce**, a odnosi između podataka definiraju se pomoću **ključeva**. Primjeri relacijskih baza podataka uključuju MySQL, PostgreSQL, SQLite, Oracle.
2. **Nerelacijske baze podataka** (*eng. NoSQL database*) pohranjuju podatke u formatu koji nije tabličan. Nerelacijske baze podataka koriste različite modele za pohranu podataka, kao što su **dokumenti**, **ključ-vrijednost**, **stupci** ili **grafovi**. Primjeri nerelacijskih baza podataka uključuju MongoDB, Cassandra, Redis, Neo4j.

Postoje **prednosti i nedostaci** oba pristupa, a odabir baze podataka ovisi o specifičnim zahtjevima projekta. Općenito, nerelacijske baze podatke pružaju veću fleksibilnost jer ne zahtijevaju unaprijed definiranu shemu. To ih čini idealnim za aplikacije koje rade s velikim količinama nestrukturiranih podataka ili polustrukturiranih podataka.

Dokumenti u MongoDB bazi podataka pohranjeni su u **JSON** formatu (*Binary JSON*), koji je binarna reprezentacija JSON formata.

Dva osnovna gradivna elementa MongoDB baze podataka su **dokumenti** i **kolekcije**:

- **Dokument** (*eng. Document*) je ustvari **jedan zapis** (*eng. record*), koji se prikazuje strukturom koja sadrži ključ-vrijednost parove, baš kao i JSON objekt.
- **Kolekcija** (*eng. Collection*) je **skup dokumenata**. Kolekcije u MongoDB bazi podataka su ekvivalent tablicama u relacijskim bazama podataka i služe za **grupiranje srodnih dokumenata**, ali bez strogo definirane sheme kao u relacijskim bazama podataka.



Slika 1: MongoDB - popularna nerelacijska dokumentno-orijentirana baza podataka (dostupno na <https://www.mongodb.com/>)

1.1 MongoDB Atlas

MongoDB moguće je koristiti na više načina, ovisno o potrebama projekta na kojem radimo. Moguće ga je preuzeti i instalirati na računalo lokalno, međutim mi to nećemo raditi za potrebe ovog kolegija, već ćemo umjesto toga koristiti Cloud uslugu MongoDB Atlas.

MongoDB Atlas je **Cloud DBaaS** (*eng. Database-as-a-Service*) usluga koja omogućuje jednostavno stvaranje, upravljanje i skaliranje MongoDB baza podataka u **"oblaku"**. Usluga je dostupna na domeni <https://www.mongodb.com/docs/atlas/> i omogućuje brzo postavljanje MongoDB baze podataka bez potrebe za instalacijom i konfiguracijom lokalnog MongoDB poslužitelja.



Slika 2: MongoDB je DBaaS usluga u Cloudu koja omogućuje izradu *clustera* baza podataka kroz 3 najveća *Cloud providera*: AWS, Azure i GCP.


Atlas značajno pojednostavljuje upravljanje i održavanje MongoDB baze podataka. Developer se može fokusirati na razvoj aplikacije, dok se MongoDB Atlas brine o infrastrukturi i sigurnosti baze podataka, kao i o automatskom skaliranju (eng. *auto-scaling*) i replikaciji podataka (eng. *data replication*).

Ova usluga se plaća, ali [postoji i besplatan plan](#) za male aplikacije i učenje. Za potrebe vašeg projekta i ovog kolegija, dovoljno je koristiti upravo besplatan plan.

Prvi korak je registracija MongoDB Atlas računa. Registrirajte se na <https://www.mongodb.com/cloud/atlas/register> i slijedite upute. Preporuka je koristiti Google račun za prijavu (možete upotrijebiti i studentski email) ili GitHub račun.

1. Jednom kad se prijavite, **morate stvoriti novu organizaciju**. Organizacija je najviša razina u MongoDB Atlasu i služi za grupiranje projekata i timova. Izradu organizacije možete započeti klikom na **Create Organization** unutar `/preferences/organizations` stranice.

Organizations




Slika 3: MongoDB Atlas - Izrada organizacije (dostupno na <https://cloud.mongodb.com/v2#/preferences/organizations>)

Organizaciju nazovite **FIPU**, **FIPU-WA** ili nešto u tom stilu, odaberite **MongoDB Atlas** i kliknite **Next**.

Možete dodati i članove vaše organizacije, za sada preskočite ovaj korsak i kliknite na **Create Organization**.

2. **Nakon što ste stvorili organizaciju, morate stvoriti projekt**. Projekt je druga razina u hijerarhiji MongoDB Atlasu i služi za grupiranje baza podataka i podjelu resursa između timova i različitih aplikacija.

Mi ćemo izraditi samo jedan projekt, možete ga nazvati **FIPU-WA-Project**. Kliknite na **New Project**, unesite naziv projekta i odaberite **Next**.



Slika 4: MongoDB Atlas - Izrada projekta (dostupno na <https://cloud.mongodb.com/v2#/projects>)

Preskočite dodavanje članova projekta i kliknite na **Create Project**.

Napomena: U novim verzijama MongoDB Atlasa, izradom organizacije automatski se stvara i zadani projekt s istim nazivom. Međutim, moguće je dodati i više projekata unutar jedne organizacije. *Primjer: imate organizaciju za vašu tvrtku, a unutar nje imate projekte za različite aplikacije, timove ili klijente.*

3. Nakon što ste stvorili projekt, možete stvoriti cluster. Cluster je ustvari MongoDB baza podataka koja se izvršava u oblaku. Radi se ustvari o skupini MongoDB poslužitelja koji rade zajedno kako bi osigurali visoku dostupnost i pouzdanost baze podataka.

Odaberite **Create a cluster** → **M0 Cluster** (besplatni plan za testiranje i učenje).

MongoDB Atlas za vas rješava sve tehničke detalje oko postavljanja i konfiguracije, uključujući infrastrukturu gdje će se baza podataka *deployati*. Međutim možete izabrati Cloud poslužitelja i regiju koja je fizički najbliža vašoj lokaciji (u produkciji - kada imate stvarne korisnike, važno je odabrati regiju koja je najbliža većini vaših korisnika kako bi se smanjila latencija i poboljšala brzina pristupa bazi podataka).

Od Cloud poslužitelja, moguće je odabrati **AWS**, **Azure** ili **GCP**. Mi ćemo odabrati **AWS** → **Frankfurt (eu-central-1)**.

Dodijelite i neki naziv *clusteru*, npr. **FIPU-WA-Cluster** i kliknite na **Create Deployment**.

Dodatno, možete i odabrati opciju **Preload sample dataset** kako bi se u vašu bazu podataka učitao uzorak podataka za testiranje i eksperimentiranje.

M10 \$0.09/hour
Dedicated cluster for development environments and low-traffic applications.
STORAGE: 10 GB, RAM: 2 GB, vCPU: 2 vCPUs

Serverless \$0.12/1M reads
For application development and testing, or workloads with variable traffic.
STORAGE: Up to 1TB, RAM: Auto-scale, vCPU: Auto-scale

M0 Free
For learning and exploring MongoDB in a cloud environment.
STORAGE: 512 MB, RAM: Shared, vCPU: Shared

Free forever! Your free cluster is ideal for experimenting in a limited sandbox. You can upgrade to a production cluster anytime.

Configurations
Name: FIPU-WA-Cluster
Provider: AWS, Google Cloud, Azure
Region: Frankfurt (eu-central-1) ★ Low carbon emissions

Quick setup
☒ Automate security setup
☒ Preload sample dataset

I'll do this later Go to Advanced Configuration Create Deployment

Slika 5: MongoDB Atlas - Izrada clustera (dostupno na <https://cloud.mongodb.com/v2#/clusters>)

Nakon što se *cluster* izradi, morat ćete izraditi novog korisnika koji će se koristiti za pristup *clusteru*. Automatski će se unijeti: vaša **javna IP adresa**, **korisničko ime** i **generirana lozinka**.

Napomena: Javna IP adresa unijet će se ako ste prilikom izrade *clustera* odabrali opciju **Automate security setup**. Ako niste, u nastavku je prikazano kako ručno dodati IP adresu.

Spremite lozinku jer će vam uskoro trebati za spajanje na izrađeni *cluster*.

Connect to FIPU-WA-Cluster

1. Set up connection security 2. Choose a connection method 3. Connect

You need to secure your MongoDB Atlas cluster before you can use it. Set which users and IP addresses can access your cluster now. [Read more](#)

1. Add a connection IP address
✓ Your current IP address (89.164.116.219) has been added to enable local connectivity. Only an IP address you add to your Access List will be able to connect to your project's clusters. Add more later in [Network Access](#).

2. Create a database user
This first user will have [atlasAdmin](#) permissions for this project.
We autogenerated a username and password. You can use this or create your own.
ⓘ You'll need your database user's credentials in the next step. Copy the database user password.

Username: laskovi Password: [REDACTED] SHOW Copy

Create Database User

Close Choose a connection method

Slika 6: MongoDB Atlas - Izrada korisnika za pristup *clusteru*. **Obavezno pohranite generiranu lozinku!** Ipak ako ne pohranite, možete ju resetirati kasnije...

Spremni smo za povezivanje s Mongom! 🍀

2. Povezivanje na cluster u MongoDB Atlasu


Jednom kad ste uspješno napravili *cluster* u MongoDB Atlasu, možete se povezati na njega na više načina:

- [MongoDB Compass](#) aplikacija (Desktop GUI za MongoDB; omogućuje jednostavan pregled i manipulaciju podacima u bazi)
- [MongoDB Shell](#) (CLI za MongoDB; omogućuje izvršavanje naredbi nad bazom podataka i pregled podataka - jako korisna stvar!)
- [MongoDB Node.js native driver](#) (Node.js biblioteka za povezivanje na MongoDB bazu podataka; ovo ćemo koristiti u nastavku skripte)
- [MongoDB for VS Code](#) (VS Code ekstenzija za MongoDB; omogućuje pregled podataka u bazi iz VS Code, vrlo praktično u razvoju)

Mi ćemo u nastavku koristiti **MongoDB native driver za Node.js** kako bismo se povezali na bazu podataka unutar našeg Express poslužitelja.

Hint: Moguće je (i preporučljivo) isprobati i druge alate za povezivanje, kako biste imali bolji uvid u podatke u bazi i kako biste mogli brže i jednostavnije raditi s podacima na više razina apstrakcije, npr. kroz GUI aplikaciju (MongoDB Compass) ili kroz VS Code ekstenziju.

Ako ste sve odradili kako treba, trebali biste vidjeti podatke o vašem *clusteru* u MongoDB Atlasu. Odabirom na **Browse Collections** možete vidjeti i kolekcije koje su automatski kreirane u vašoj bazi podataka ako ste odabrali opciju **Preload sample dataset**.




Slika 7: MongoDB Atlas - Pregled zadane *sample* baze podataka (*sample_mflix* i njenih kolekcija)

Prije nego krenemo s povezivanjem na Atlas, potrebno je unutar **Security/Network Access** dodati IP adresu u **whitelist** kako bi se mogli povezati na bazu podataka s našeg računala. Ovo je dodatna sigurnosna mjera kako bi se spriječilo neovlašteno povezivanje na bazu podataka.

Međutim, kako se dinamička IP adresa našeg računala povremeno mijenja, nije loše **privremeno** (isključivo u procesu razvoja i učenja), omogućiti pristup sa svih IP adresa. Ovo možete učiniti tako da dodate zapis **0.0.0.0/0**.

Napomena: `0.0.0.0/0` nije isto što i `localhost`! Adresa `localhost` predstavlja samo vaše lokalno računalo (npr. gdje se izvršava Express ili drugi poslužitelj), dok adresa `0.0.0.0/0` predstavlja sve IPv4 adrese te kad se upiše kao firewall/whitelist pravilo, omogućuje pristup s bilo koje IP adrese na internetu. **Nikako ne smijete ostaviti ovo pravilo u produkcijskoj bazi podataka jer predstavlja ogroman sigurnosni rizik!**



Slika 8: MongoDB Atlas - Dodavanje IP adrese u *whitelist* kako bi se omogućilo povezivanje na bazu podataka s vašeg računala.

2.1 Priprema Express poslužitelja

Prije nego krenemo s povezivanjem na bazu podataka, pripremit ćemo osnovni Express poslužitelj. Vraćamo se na poslužitelj za naručivanje pizze iz prethodnih vježbi 🍕🍕🍕

Napomena: Možete upotrijebiti gotovi kôd iz prethodnih vježbi ili napraviti novi projekt - kako god želite.

Napravite novi direktorij i definirajte osnovni Express poslužitelj u `index.js` datoteci:

```
// index.js
import express from 'express';

const app = express();

app.use(express.json());


app.get('/', (req, res) => {
  res.send('Pizza app');
});

const PORT = 3000;
app.listen(PORT, error => {
  if (error) {
    console.log('Greška prilikom pokretanja servera', error);
  }
  console.log(`Pizza poslužitelj dela na http://localhost:${PORT}`);
});
```

2.2 MongoDB Connection string

Povezivanje koristeći MongoDB *native driver* za Node.js realizira se kroz tzv. **Connection string**. *Connection string* je niz znakova koji sadrži informacije potrebne za povezivanje na vaš konkretan *cluster* u MongoDB Atlasu.

Odaberite svoj *cluster* u MongoDB Atlasu i kliknite na **Connect** gumb. Odaberite **Drivers**.




Slika 9: MongoDB Atlas - Odabir *drivera* za povezivanje na bazu podataka.

Odaberite **Node.js** kao *driver* i najnoviju verziju *drivera*. Mi ćemo koristiti **6.7 or later**.

Napomena: Moguće je koristiti i **Mongoose** *driver* za povezivanje na MongoDB bazu. Mongoose je ORM (Object-Relational Mapping) biblioteka za MongoDB i omogućuje definiranje sheme i modela za Mongo baze. Više o Mongoose biblioteci možete pročitati na <https://mongoosejs.com/>. Rad s ovom bibliotekom je izvan opsega ovog kolegija, ali je topla preporuka za ozbiljnije produkcijske aplikacije.

Kopirajte vaš *Connection string* na sigurno mjesto, tamo gdje ste kopirali i generirani password



Slika 10: MongoDB Atlas - Odaberite Node.js driver, kopirajte generirani *connection string*. i lozinku.

Struktura *MongoDB connection stringa* izgleda ovako:

```
mongodb+srv://<username>:<password>@<cluster>.cluster.mpyeq.mongodb.net/?  
retryWrites=true&w=majority&appName=<appname>
```

Sastoji se od:

- **Mongo protokola:** `mongodb+srv://`
- **Credentials:** `<username>:<password>`
- **Hostname/IP adresa i port:** `<cluster>.cluster.mpyeq.mongodb.net`
- **Dodatnih opcija:** `?retryWrites=true&w=majority&appName=<appname>`



Slika 11: Struktura MongoDB *connection stringa*.

Važno! *Connection string* je privatni podatak i ne smije se dijeliti s drugima (**sadrži sve podatke potrebne za spajanje na vaš Mongo cluster**). Ukoliko ga dijelite, osigurajte se da ste ga uklonili iz javno dostupnih repozitorija ili datoteka. U nastavku ćemo vidjeti kako možemo koristiti `.env` datoteku za pohranu osjetljivih podataka te ju dodati u `.gitignore` kako bi se spriječilo slanje osjetljivih podataka na GitHub udaljeni repozitorij.

2.3 db.js

Prije nego što se povežemo na bazu podataka, moramo instalirati MongoDB *native driver* za Node.js. Instalirajte `mongodb` paket koristeći `npm`:

```
→ npm install mongodb
```

Do sad smo naučili nekoliko dobrih praksi u razvoju poslužitelja:

- ne želimo sav kod “krcati” u `index.js` datoteku, već stvaramo **modularnu strukturu aplikacije** kroz Express Router objekte.
- u `index` datoteci koristimo `app.use()` metodu za povezivanje Router objekata na određene rute.

Jednako tako, i kod povezivanja na bazu podataka, **dobra praksa je izdvojiti programski kod za povezivanje u zasebnu datoteku**. Stvorite novu datoteku `db.js` u kojoj ćemo definirati logiku povezivanja na bazu podataka. Glavninu logike možete pronaći prilikom generiranja connection stringa u MongoDB Atlasu, međutim ona je zapisana u *commonjs* sintaksi, mi ćemo ju pojednostaviti kroz *ES6* sintaksu.

Ideja je da možemo koristiti `db.js` datoteku kao modul u našem Express poslužitelju, kako bismo se u svakoj datoteci (npr. u Router objektima) mogli spojiti na bazu podataka.

```
→ touch db.js
```

Uključit ćemo `MongoClient` klasu iz `mongodb` paketa:

```
import { MongoClient } from 'mongodb';
```

Pohranjujemo *Connection string* u varijablu (uobičajeno je izdvojiti naziv clustera, username i lozinku u zasebne varijable radi preglednosti):

```
const username = '<username>'; // vaše Mongo korisničko ime
const password = '<password>'; // vaša Mongo lozinka
const cluster = '<cluster>'; // naziv vašeg clustera

// Pripazite! nakon lozinke, MongoDB će konkatenirati naziv vašeg clustera i random string
// (.cluster.mpyeq.mongodb.net)
const mongoURI =
`mongodb+srv://${username}:${password}@${cluster.toLowerCase()}.mongodb.net/?
appName=${cluster}`;
```

Zatim definiramo asinkronu funkciju `connectToDatabase()` koja će se koristiti za povezivanje na bazu podataka:

Definirat ćemo `client` varijablu koja će sadržavati **instancu MongoClient klase**:

Sintaksa:

```
const client = new MongoClient(url: string, options?: MongoClientOptions);
```

U opcijama možemo definirati objekt s dodatnim opcijama, za sada ćemo to ostaviti prazno.

Popis svih opcija možete pronaći na [sljedećoj poveznici](#).

Jednom kad definirate klijent, povezujemo se metodom `client.connect()`.

Postupak je sljedeći:

- Kod ćemo omotati `try-catch` blokom kako bismo uhvatili eventualne greške prilikom spajanja na bazu podataka (npr. pogrešan *connection string*, nepostojeći cluster i sl.)
- U slučaju greške, ispisujemo poruku u konzolu i bacamo grešku (koristimo `throw` naredbu).
- `throw` naredba prekida izvršavanje trenutne funkcije i vraća grešku.
- Grešku koju baca `throw` naredba možemo uhvatiti koristeći `catch` blok kasnije u kodu.
- U varijablu `db` spremamo referencu na bazu podataka koju smo odabrali (u našem slučaju `sample_mflix`).

```
async function connectToDatabase() {
  try {
    const client = new MongoClient(mongoURI); // stvaramo novi klijent
    await client.connect(); // spajamo se na klijent
    console.log('Uspješno spajanje na bazu podataka');
    let db = client.db('naziv_baze_podataka'); // odabiremo bazu podataka
    return db;
  } catch (error) {
    console.error('Greška prilikom spajanja na bazu podataka', error);
    throw error;
  }
}
```

Izvesti ćemo funkciju `connectToDatabase` kako bismo ju mogli koristiti u drugim datotekama:

```
export { connectToDatabase };
```

Unutar `index.js` datoteke, *importat* ćemo funkciju `connectToDatabase` i pozvati ju nakon definiranja instance poslužitelja:

```
import { connectToDatabase } from './db.js';

const app = express();

let db = await connectToDatabase();
```

Ponovno pokrenite Express poslužitelj i provjerite ispis u konzoli. Ako se uspješno spojite na bazu podataka, trebali biste vidjeti poruku: `Uspješno spajanje na bazu podataka`.

2.4 Varijable okoline - `dotenv` modul

Kako bismo spriječili učitavanje osjetljivih podataka na GitHub (ili drugi sustav za javnu pohranu Git repozitorija), koristit ćemo `.env` datoteku za **pohranu osjetljivih podataka**.

Općenito, **varijable okoline** (*eng. environment variables*) su varijable koje se koriste za pohranu osjetljivih podataka kao što su lozinke, API ključevi, *database credentials*, *recovery-phase* izrazi ili recimo neke postavke koje mogu varirati ovisno o okolini u kojoj se aplikacija izvršava (npr. razvojna, testna, produkcijska okolina gotovo uvijek mora koristiti različiti skup varijabli okoline).

- U našem slučaju, **želimo spriječiti pohranu *Connection stringa* MongoDB baze podataka na GitHub.**

U Node.js aplikacijama, možemo koristiti `dotenv` paket za učitavanje *environment* varijabli iz `.env` datoteke.

Instalirajte `dotenv` paket koristeći `npm`:

```
→ npm install dotenv
```

Stvorite `.env` datoteku u korijenskom direktoriju vašeg projekta:

```
→ touch .env
```

```
→ ls -a # prikazuje sve datoteke, uključujući skrivene
```

Prisjetimo se da datoteke koje počinju s točkom (`.`) su skrivene datoteke na većini operacijskih sustava.

Ako koristite terminal, morate koristiti zastavicu `-a` za ispisivanje skrivenih datoteka, npr. `ls -a`.

Unutar `.env` datoteke, definirajte vaše osjetljive podatke. Uobičajeno je environment varijable pisati velikim slovima i koristiti `_` za razdvajanje riječi:

Svi podaci s desne strane znaka jednakosti (`=`) su stringovi, **ne trebate koristiti navodnike**.

```
MONGO_URI=mongodb+srv://<username>:<password>@<cluster>.cluster.mpyeq.mongodb.net/?  
retryWrites=true&w=majority&appName=<appname>  
MONGO_DB_NAME=sample_mflix
```

Nakon što ste pohranili osjetljive podatke u `.env` datoteku, možete ih učitati u vašu aplikaciju koristeći `dotenv` paket.

U `db.js` datoteci, uvest ćemo `dotenv` paket i učitati osjetljive podatke iz `.env` datoteke:

```
import { config } from 'dotenv';  
  
config(); // učitava osjetljive podatke iz .env datoteke
```

Varijablama sad pristupamo unutar ugrađenog objekta `process.env`:

Testirajmo:

```
console.log(process.env.MONGO_URI);  
console.log(process.env.MONGO_DB_NAME);
```

Hint: Ako ne radi, pokušajte pokrenuti novu instancu terminala i ponovno pokrenuti poslužitelj.

Sada možemo zamijeniti `mongoURI` i `db_name` varijable s `process.env.MONGO_URI` i `process.env.MONGO_DB_NAME`:

```
import { MongoClient } from 'mongodb';

import { config } from 'dotenv';

config(); // učitava osjetljive podatke iz .env datoteke

let mongoURI = process.env.MONGO_URI;
let db_name = process.env.MONGO_DB_NAME;

async function connectToDatabase() {
  try {
    const client = new MongoClient(mongoURI); // stvaramo novi klijent
    await client.connect(); // spajamo se na klijent
    console.log('Uspješno spajanje na bazu podataka');
    let db = client.db(db_name); // odabiremo bazu podataka
    return db;
  } catch (error) {
    console.error('Greška prilikom spajanja na bazu podataka', error);
    throw error;
  }
}

export { connectToDatabase };
```

Na kraju, ne smijemo zaboraviti dodati `.env` datoteku u `.gitignore` kako bismo spriječili njeno slanje na GitHub.

Osim `.env` datoteke, možete dodati i `node_modules` direktorij kako biste spriječili pohranu svih paketa našeg projekta. Ovo je korisno jer ne želimo slati pakete na GitHub, budući da ih možemo ponovno instalirati koristeći `npm install` ako su definirani u `package.json` datoteci.

Datoteku `.gitignore` dodajete u korijenskom direktoriju vašeg projekta, sa sljedećim sadržajem:

```
node_modules
.env
```

```
→ touch .gitignore
```

```
# ili direktno sa echo naredbom (operator >> dodaje tekst na kraj datoteke, dok > prepisuje postojeći sadržaj)
→ echo "node_modules\n.env" >> .gitignore
```

Struktura Expressa sad bi trebala izgledati otprilike ovako:

```
.  
├─ .env  
├─ .gitignore  
├─ db.js  
├─ index.js  
├─ node_modules  
├─ package-lock.json  
└─ package.json
```

3. CRUD operacije na MongoDB bazi podataka

CRUD (*Create, Read, Update, Delete*) operacije predstavljaju četiri osnovne vrste operacija koje se mogu izvršiti nad podacima u bilo kojoj bazi podataka.

U MongoDB bazi podataka, CRUD operacije se izvršavaju nad **dokumentima u kolekcijama**.

1. **Create** (*stvaranje*) - dodavanje novog dokumenta u kolekciju
2. **Read** (*čitanje*) - dohvaćanje podataka iz kolekcije
3. **Update** (*ažuriranje*) - ažuriranje postojećeg dokumenta u kolekciji
4. **Delete** (*brisanje*) - brisanje dokumenta iz kolekcije

Vidimo da su CRUD operacije analogne HTTP metodama (GET, POST, PUT/PATCH, DELETE) koje koristimo u **RESTful** dizajnu programskih sučelja.

Ovisno o kompleksnosti strukture projekta, CRUD operacije moguće je pisati direktno unutar definicije ruta u Express poslužitelju, ili ih možemo izdvojiti u zasebne datoteke kako bismo imali bolju organizaciju koda. **Za početak ćemo ih pisati direktno unutar definicije ruta.**

3.1 GET operacija

Prisjetimo se 2 osnovne GET rute koje smo definirali u Express poslužitelju za dohvaćanje svih pizza i pojedinačne pizze:

```
app.get('/pizze', (req, res) => {
  res.status(200).json(pizze);
});

app.get('/pizze/:id', (req, res) => {
  const id = req.params.id;
  const pizza = pizze.find(pizza => pizza.id === id); // Oprez, ovo je metoda Array.find()
  // koja dohvaća prvi element koji zadovoljava callback predikat
  res.status(200).json(pizza);
});
```

Podatke smo prethodno definirali *in-memory*, ali i unutar JSON datoteke, a sada ćemo ih pohraniti u MongoDB Atlas.

Prije nego to napravimo, pokušat ćemo dohvatiti postojeće podatke iz predefinirane baze podataka `sample_mflix`. Prvi korak je definirati kolekciju iz koje ćemo dohvatiti podatke.

U MongoDB Atlasu, kliknite na **Browse Collections** za definirani `cluster` i odaberite kolekciju iz koje ćemo dohvatiti podatke. Recimo, iz kolekcije `users` (`sample_mflix.users`).

Zapamti! `cluster` = `FIPU-WA-Cluster`, baza podataka = `sample_mflix`, kolekcija = `users`, dokument = pojedinačni zapis sa `ObjectId`-om unutar kolekcije.

Kolekciju dohvaćamo koristeći `db.collection()` metodu, gdje je `db` referenca na bazu podataka koju smo dobili kao rezultat funkcije `connectToDatabase()`.

```
let allUsers = db.collection('users'); // ne vraća podatke, već referencu na kolekciju ako ona postoji
```

Mongo metoda: `collection().find()`

Možemo dohvatiti sve dokumente iz kolekcije koristeći `collection().find()` metodu (ekvivalentno SQL upitu `SELECT * FROM users`).

Važno! Ovo metoda, različita je od metode `Array.find()` koju smo koristili u prethodnim primjerima. Ova metoda **vraća `FindCursor`** objekt kad se poziva nad MongoDB kolekcijom, a ne *in-memory* poljem.

`FindCursor` objekt je pokazivač na rezultate upita koji omogućuje iteraciju kroz rezultate.

Sintaksa:

```
db.collection('naziv_kolekcije').find(filter, options);
```

gdje su opcionalni parametri:

- `filter` - opcionalni objekt koji **sadrži kriterije pretrage** (npr. `{ name: 'John' }`), ekvivalentno `WHERE name = 'John'` SQL izrazu; ako se ne navede - vraćaju se svi dokumenti. Postoji puno kriterija pretrage, više o tome u nastavku
- `options` - opcionalni objekt koji **sadrži dodatne opcije** (npr. `{ projection: { name: 1, age: 1 } }`), ekvivalentno `SELECT name, age FROM ...` SQL izrazu. U nastavku više o ovom argumentu, za sada ćemo ga ostaviti praznim.

Dohvatit ćemo sve korisnike iz kolekcije `users`:

```
let allUsers = db.collection('users').find(); // dohvaća sve dokumente iz kolekcije - vraća FindCursor objekt

//import { FindCursor } from 'mongodb';
console.log(allUsers instanceof FindCursor); // true - allUsers je FindCursor objekt
```

`find()` metoda vraća `FindCursor` objekt - **pokazivač na rezultate upita**. Da bismo dohvatili same rezultate, koristimo `Iterator.toArray()` metodu.

```
let usersDocuments = await allUsers.toArray(); // pretvaramo FindCursor u JavaScript Array
```

Ili možemo prvo pohraniti kolekciju u varijablu (sinkrono), a zatim dohvatiti sve dokumente (asinkrono):

```
app.get('/users', async (req, res) => {
  let users_collection = db.collection('users'); // pohranjujemo referencu na kolekciju
  let allUsers = await users_collection.find().toArray(); // dohvaćamo sve korisnike iz kolekcije i pretvaramo FindCursor objekt u JavaScript polje
  res.status(200).json(allUsers);
});
```

Pošaljite HTTP zahtjev na `http://localhost:3000/users` i provjerite jesu li podaci uspješno dohvaćeni iz baze podataka.

Moguće je napisati i u jednoj liniji koda:

```
let actualDocuments = await db.collection('users').find().toArray();
```


3.1.1 GET /pizze

Sada ćemo izraditi kolekciju s podacima o pizzama i implementirati odgovarajuće GET rute za dohvaćanje **svih pizza** i **pojedinačne pizze**.

Otvorite sučelje vašeg Atlas Clustera i odaberite `Browse Collections`. Kliknite na `+ Create Database` i nazovite bazu podataka `pizza_db`, `pizzeria` ili sl.

Definirajte prvu kolekciju i nazovite ju `pizze`.

Jednom kad to napravite, vidjet ćete praznu kolekciju `pizze`. Kliknite na `Insert Document` - unijet ćemo nekoliko dokumenata.



Slika 12: MongoDB Atlas - Ručni unos novog dokumenta u kolekciju `pizze`.

Prvo što ćete uočiti je da je **podatak ID već unesen**, u MongoDB bazi podataka svaki dokument mora imati jedinstveni identifikator, a on se označava s `_id` poljem te je tipa `ObjectId`.

Podatke na web sučelju Atlasa možete dodavati na dva načina:


- pisanjem `JSON` strukture (ustvari je `BSON`)
- kroz sučelje za unos podataka

```
{ "_id": { "$oid": "674d808cbbb8072b29ae839f" } }
```

Na postojeći zapis dodajemo polja `naziv` i `cijena`.

```
{
  "_id": { "$oid": "674d808cbbb8072b29ae839f" },
  "naziv": "Capricciosa",
  "cijena": 11
}
```

Preko sučelja izgleda ovako:



Slika 13: MongoDB Atlas - Unos podataka o pizzi kroz JSON sučelje.

Dodajte sljedeće pizze u kolekciju:

```
{
  "naziv": "Margherita",
  "cijena": 9
},
{
  "naziv": "Quattro Stagioni",
  "cijena": 13
},
{
  "naziv": "Quattro Formaggi",
  "cijena": 15
},
{
  "naziv": "Vegetariana",
  "cijena": 12
},
{
  "naziv": "Šunka sir",
  "cijena": 10
}
```

Postupak je moguće i malo ubrzati kloniranjem postojećeg zapisa (Mongo će automatski generirati novi `_id` za svaki!):



Slika 14: MongoDB Atlas - Kloniranje postojećeg zapisa radi ubrzanja unosa podataka.


Nakon što ste dodali pizze, možemo ih dohvatiti na isti način kao prethodno korisnike, koristeći metodu `collection().find()`

```
app.get('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze'); // referenca na kolekciju 'pizze'
  let allPizze = await pizze_collection.find().toArray(); // pretvorba u Array
  res.status(200).json(allPizze);
});
```

Napomena, potrebno je još unutar `.env` datoteke promijeniti vrijednost varijable `MONGO_DB_NAME` na `pizza_db`, ili kako ste već nazvali bazu.

```
MONGO_DB_NAME=pizza_db
```

Testirajte dohvaćanje svih pizza na ruti: `http://localhost:3000/pizze`



Slika 15: Postman - Dohvaćanje svih pizza iz MongoDB baze podataka. Ako ste dobili status kod 200 i niz objekata, sve radi kako treba!

3.1.2 GET /pizze/:naziv

U NoSQL bazama podataka nemamo strogo definiranu shemu (eng. *Database schema*) kao u relacijskim bazama podataka pa je moguće “na licu mjesta” mijenjati strukturu dokumenata.

Samim tim, nemamo niti strogo definirane ključeve, poput **Primary key** u relacijskim bazama podataka.

MongoDB indeksi (eng. Indexes)


Međutim, “postoji nešto što nalikuje ključevima”, a to su indeksi. **Indeksi (eng. Index)** su struktura podataka koja omogućuje brže pretraživanje podataka u bazi podataka. Preciznije, radi se o **B-stablima** (eng. *B-trees*) i sličnim B+ like stablastim strukturama podataka.

Više o B-stablima i sličnim strukturama učit ćete na petoj godini studija, na super zabavnom kolegiju [Napredni algoritmi i strukture podataka](#). Stay tuned! 😊

Bez indeksa, NoSQL baze podataka morale bi pretraživati svaki dokument u kolekciji kako bi pronašle odgovarajući dokument. **Indeksi omogućuju brže pretraživanje podataka jer se podaci pretražuju prema indeksu koji pokazuju na grupe podataka, a ne prema samim dokumentima.** Samim tim, sve metode pretraživanja, filtriranja i sortiranja podataka su brže kada su podaci indeksirani.

U MongoDB bazi podataka, indeksi se mogu ručno izraditi, a neki se i automatski stvaraju, npr. za ključ `_id`, koji je **jedinstveni identifikator svakog dokumenta**. Ovaj indeks omogućuje brže pretraživanje podataka prema `_id` ključu, što je i *defaultna* vrijednost kod metode `collection().find()`.

Kada otvorite određenu kolekciju na Atlasu, pronađite sekciju `Indexes`



Slika 16: MongoDB Atlas - Pregled definiranih indeksa unutar kolekcije `pizze`.

Uočite postojeći indeks na `_id` polje, koji je automatski dodan prilikom dodavanja prvog dokumenta u kolekciju. Ovo znači da je pretraživanje po `_id` polju brže nego pretraživanje po drugim poljima koja nisu indeksirana.

Do sad smo definirali GET rutu za dohvaćanje pojedine pizze po ID-u. Međutim, tada su nam ID-evi bili jednostavni brojevi koje smo ručno definirali i bili su sekvencijalnog slijeda `0, 1, 2, 3, 4, 5, ...`. Dodavanjem zapisa, jednostavno smo dohvatili posljednji ID i dodali `+1`.

Ovdje to nije moguće jer su nam ID-evi kompleksni `ObjectId` objekti koje MongoDB automatski dodaje prilikom dodavanja novog zapisa. Samim tim, nešto je kompliciranije definirati endpoint `/pizze/:id`.

Kako se radi o aplikaciji za pizzeriju, možemo se složiti da su **pizze u meniju također jedinstveni podaci** pa možemo iskoristiti `naziv` ključ kao ključ po kojem ćemo pretraživati/dohvaćati.

Međutim, rekli smo da je pretraživanje po `_id` polju brže jer je indeksirano. Kako ćemo onda pretraživati po `naziv` polju?

▼ Spoiler alert! Odgovor na pitanje

Jednostavno! Dodat ćemo i indeks na za polje `naziv`.

Dodavanje indeksa možemo odraditi putem Atlas web sučelja ili direktno u kodu. Za sada ćemo direktno preko web sučelja.

Pizzu po nazivu želimo dohvatiti unutar GET rute `/pizze/:naziv`

Koristeći metodu `collection().find()` možemo definirati filter pretrage:

```
collection('naziv_kolekcije').find({ naziv: 'naziv_pizze' });
```

Mongo metoda: `collection().findOne()`

Možemo koristiti i metodu `collection().findOne()` koja vraća samo prvi dokument koji zadovoljava kriterije pretrage (`filter`).

Metoda u principu radi poput `Array.find()` metode, ali ne pišemo *callback* funkciju, već `filter` objekt.

Sintaksa:

```
collection('naziv_kolekcije').findOne(filter); // vraća samo 1 dokument
```

```
collection('naziv_kolekcije').findOne({ naziv: 'naziv_pizze' }); // vrati prvi dokument koji ima naziv 'naziv_pizze'
```

Ako koristimo metodu `findOne()`, uvijek dobivamo samo jedan dokument pa ne moramo koristiti `toArray()` metodu. Ova metoda ne vraća `FindCursor` objekt, već direktno dokument ako postoji ili `null` ako ne postoji.

Dodajemo parametar rute `naziv` koji ćemo koristiti za pretragu:

```
app.get('/pizze/:naziv', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let naziv_param = req.params.naziv;
  let pizza = await pizze_collection.find({ naziv: naziv_param }).toArray();
  // ili
  let pizza = await pizze_collection.findOne({ naziv: naziv_param }); // samo 1 rezultat,
  ne koristimo metodu Iterator.toArray()
  res.status(200).json(pizza);
});
```

Testirajte, npr. slanjem zahtjeva na `http://localhost:3000/pizze/Margherita`.

- Kod radi, **ali nismo još dodali indeks**.

Postoji mnogo vrsta indeksa u Mongu, mi ćemo za sada dodati tzv. **Single Field Text Index** na `naziv` polje koji će optimizirati sljedeću pretragu:

```
db.pizze.find({ naziv: 'Capricciosa' });
```

Indeksi se definiraju *ključ-vrijednost* sintaksom:

```
<naziv_polja>: <tip_indeksa>
```

U našem slučaju:

```
"naziv" : 1,
```

- Naziv polja/ključa je `naziv`, a tip indeksa je `1` što označava **uzlazni indeks**, dok `-1` označava **silazni indeks**. Uzlazni indeks znači da će se podaci sortirati od najmanjeg prema najvećem (A-Z, 0-9), dok silazni indeks znači da će se podaci sortirati od najvećeg prema najmanjem (Z-A, 9-0).

Možemo dodati i `unique` **svojstvo indeksa unutar opcija**, kako bismo osigurali da su svi nazivi pizza jedinstveni (zamislite ovo kao `SQL UNIQUE` ograničenje ili `BEFORE INSERT TRIGGER`).

```
{
  "unique": true
}
```

Dodajemo indeks preko Atlas web sučelja:

Create Index

TIP

The best indexes for your application must take a number of factors into account. To learn about index creation best practices, read the [Index Strategies Documentation](#).

For more information on creating indexes in Data Explorer, see [Create an Index](#).

Collection

pizza_db.pizza

Fields

1	{
2	"naziv": 1
3	}

Options

{
"unique": true
}

Collation options

--

Cancel

Review

Pripazite! Ako izostavite JSON objekt (vitičaste zagrade) kod `Options`, dobit ćete grešku.

Možemo vidjeti nadodani indeks i automatski dodijeljeni naziv `naziv_1` gdje `_1` označava uzlazni indeks.

Name, Definition, and Type	Size	Usage	Properties	Action
_id REGULAR	36.0 B	< 1/min since Mon Dec 2 2024		
naziv_1 REGULAR	20.0 B	< 1/min since Mon Dec 2 2024	UNIQUE	

Testirajte kod, stvari ostaju iste, ali sada je pretraga po nazivu optimizirana (premda to ne uočavamo na malom broju podataka i malom broju GET zahtjeva).

Više o indeksima možete pročitati na [sljedećoj poveznici](#).

3.2 POST operacija

Dodat ćemo mogućnost dodavanja novih pizza u kolekciju `pizze`, a nakon toga i stvaranje narudžbe u kolekciju `narudžbe`.

3.2.1 POST `/pizze`

Definirajmo prvo kostur endpointa:

```
app.post('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let novaPizza = req.body;
  res.status(201).json(); // 201 jer smo kreirali novi resurs
});
```

Mongo metoda: `collection().insertOne()`

Novi dokument (tačno jedan) u kolekciju dodajemo pomoću `collection().insertOne()` metode:

Sintaksa:

```
db.collection('naziv_kolekcije').insertOne(object);
```

Povratna vrijednost ove metode je objekt koji sadrži:

- `acknowledged` - boolean vrijednost koja označava je li operacija uspješno izvršena (`true`) ili nije (`false`)
- `insertedId` - ID novododanog dokumenta (`ObjectId`)


Naš objekt je u tijelu HTTP zahtjeva, koji sad mora izgledati ovako:

```
{
  "naziv": "Slavonska",
  "cijena": 14
}
```

Moramo paziti na 3 stvari prilikom definiranja HTTP zahtjeva:

- da sadrži sve potrebne ključeve (`naziv`, `cijena`)
- da sadrži jedinstveni ključ `naziv` jer smo tako definirali indeksom `naziv_1`
- da je u JSON formatu

```
app.post('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let novaPizza = req.body;
  let result = await pizze_collection.insertOne(novaPizza);
  res.status(201).json(result.insertedId); // Vraćamo klijentu ID novododanog dokumenta
});
```



Slika 17: Postman - Dodavanje nove pizze u MongoDB bazu podataka. Provjerite zapis u Mongo sučelju.

Ako pokušate dodati istu pizzu, dobit ćete grešku jer smo to spriječili indeksom (ovu zabranu zamislite kao SQL UNIQUE ograničenje ili BEFORE INSERT TRIGGER)

Međutim, **greška nije obrađena pa se naš Express poslužitelj ruši...**

Ispis greške u konzoli:

```
errorResponse: {
  index: 0,
  code: 11000,
  errmsg: 'E11000 duplicate key error collection: pizza_db.pizze index: naziv_1 dup key: {
naziv: "Slavonska" }',
  keyPattern: { naziv: 1 },
  keyValue: { naziv: 'Slavonska' }
},
index: 0,
code: 11000,
keyPattern: { naziv: 1 },
keyValue: { naziv: 'Slavonska' },
[Symbol(errorLabels)]: Set(0) {}
}
```

Grešku možemo pročitati unutar `result`, preciznije u `result.errorResponse` objektu.

Kako kod "pukne" na liniji `await pizze_collection.insertOne(novaPizza);`, moramo dodati `try-catch` blok kako bismo uhvatili grešku i poslali odgovarajući status klijentu.

```
app.post('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let novaPizza = req.body;
  let result = {}; // inicijaliziramo prazan objekt (?)
  try {
    result = await pizze_collection.insertOne(novaPizza);
  } catch (error) {
    console.log(error.errorResponse);
  }
  res.status(201).json(result); // Vraćamo klijentu cijeli result objekt
});
```

Vidimo ispis `result.errorResponse` u konzoli, **pitanje**: Zašto se klijentu nije vratio objekt `result`, ako smo tako naveli u posljednjoj liniji?

▼ Spoiler alert! Odgovor na pitanje

Zato što je kod "puknuo" na liniji `await pizze_collection.insertOne(novaPizza);` i nije se izvršila linija `res.status(201).json(result);`.

Preciznije, u varijablu `result` nije spremljen rezultat operacije jer je došlo do greške.

Izvršavanje koda je preuzeo `catch` blok i ispisao samo grešku u konzoli

Dakle, `result` objekt ostaje prazan

Gotovo nikada u programiranju web poslužitelja ne želimo koristiti strukturu endpointa kao što je implementirano iznad, iz sljedećih razloga:


- ne želimo definirati inicijalno prazan `result` objekt (općenito kad definiramo inicijalno praznu varijablu, vjerojatno nešto radimo krivo)
- ne želimo vraćati korisniku cijeli `result` objekt, već **samo informacije koje su mu potrebne**
- ispravno je **premjestiti slanja HTTP odgovora unutar `try-catch` bloka**

Ispravno je sljedeće:

```
app.post('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let novaPizza = req.body;
  try {
    let result = await pizze_collection.insertOne(novaPizza);
    res.status(201).json({ insertedId: result.insertedId }); // Kad šaljem JSON, moramo
    podatak spremiti u neki ključ
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse }); // 400 jer je korisnik poslao
    neispravne podatke
  }
});
```

Testirajte dodavanje nove pizze putem HTTP klijenta, kao i dodavanje iste pizze dvaput.


Greška se sada obrađuje i klijentu se šalje cijeli objekt greške (koji onda klijent obrađuje na svojoj strani):



Slika 18: Postman - Ispravno rukovanje greškom prilikom dodavanja nove pizze u MongoDB bazu podataka.

Međutim ako dodamo novu pizzu Fantasia:

```
{
  "naziv": "Fantasia",
  "cijena": 12.5
}
```



Slika 19: Postman - Uspješno dodavanje nove pizze u MongoDB bazu podataka. Provjerite zapis u Mongo sučelju.

3.2.2 POST /narudzbe

Vrlo slično možemo dodati i novu narudžbu u kolekciju `narudzbe`. Prvo ćemo izraditi kolekciju `narudzbe` u Atlasu (iako nije nužno, MongoDB će automatski stvoriti kolekciju ako ne postoji).

Endpoint možemo definirati identično kao i `POST /pizze` budući da dodajemo točno 1 zapis, samo ćemo promijeniti naziv kolekcije.

Tijelo zahtjeva definiramo direktno na klijentskoj strani, odnosno u HTTP klijentu:

```
app.post('/narudzbe', async (req, res) => {
  let narudzbe_collection = db.collection('narudzbe');
  let novaNarudzba = req.body;
  try {
    let result = await narudzbe_collection.insertOne(novaNarudzba);
    res.status(201).json({ insertedId: result.insertedId });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});
```

Što uopće moramo definirati u tijelu zahtjeva?

Što će se desiti ako u tijelu pošaljemo samo sljedeće?

```
{
  "kupac": "Marko Marić"
}
```

▼ Spoiler alert! Odgovor na pitanje

Zapis će se dodati ispravno. Dobit ćemo dokument u narudžbama s jedinstvenim `_id` poljem i poljem `kupac`.

Isto bi se desilo i da smo na ovaj način poslali zahtjev na endpoint `POST /pizze`

Razlog tomu je što **nemamo validaciju podataka na poslužitelju, a baza podataka prihvaća sve što joj pošaljemo.**

Ponavljanje: Validacija zahtjeva na poslužitelju

Definirat ćemo jednostavnu validaciju podataka koje očekujemo u tijelu HTTP zahtjeva, kao što smo dosad radili u Expressu.

Najlakše je započeti definicijom JSON strukture koju očekujemo: Kupac je jedan, ali može naručiti više pizze. Za svaku pizzu osim naziva, moramo navesti i veličinu. Međutim, možemo naručiti dvije iste pizze, ali različitih veličina i količina.

Primjer strukture JSON tijela zahtjeva:

```
{
  "kupac": "Marko Marić",
  "narucene_pizze": [
    {
      "naziv": "Capricciosa",
      "količina": 2,
      "veličina": "srednja"
    },
    {
      "naziv": "Vegetariana",
      "količina": 1,
      "veličina": "velika"
    },
    {
      "naziv": "Capricciosa",
      "količina": 1,
      "veličina": "mala"
    },
    {
      "naziv": "Šunka sir",
      "količina": 3,
      "veličina": "srednja"
    }
  ]
}
```

Osim toga, moramo prosljediti i adresu za dostavu te broj telefona.

```

{
  "kupac": "Marko Marić",
  "adresa": "Vodnjanska 12, 52100 Pula",
  "broj_telefona": "098 123 456",
  "narucene_pizze": [
    {
      "naziv": "Capricciosa",
      "količina": 2,
      "veličina": "srednja"
    },
    {
      "naziv": "Vegetariana",
      "količina": 1,
      "veličina": "velika"
    },
    {
      "naziv": "Capricciosa",
      "količina": 1,
      "veličina": "mala"
    },
    {
      "naziv": "Šunka sir",
      "količina": 3,
      "veličina": "srednja"
    }
  ]
}

```

Kako ovo sada validirati?

Možemo u `Array` obaveznih ključeva dodati ključeve koje očekujemo: `kupac`, `adresa`, `broj_telefona` i `narucene_pizze`.

Nakon toga, za svaki ključ iz tog polja, u *callback* funkciji provjeravamo postoji li taj ključ u tijelu zahtjeva.

- prvo pretvaramo objekt `novaNarudzba` u `Array` njezinih ključeva
- zatim provjeravamo za svaki ključ iz `obavezniKljucevi` postoji li u `novaNarudzba`

```

app.post('/narudzbe', async (req, res) => {
  let narudzbe_collection = db.collection('narudzbe');
  let novaNarudzba = req.body;

  let obavezniKljucevi = ['kupac', 'adresa', 'broj_telefona', 'narucene_pizze'];

  // pretvaramo objekt novaNarudzba u Array ključeva, pa provjeravamo sa Array.includes()
  if (!obavezniKljucevi.every(kljuc => Object.keys(novaNarudzba).includes(kljuc))) {
    return res.status(400).json({ error: 'Nedostaju obavezni ključevi' });
  }

  try {
    let result = await narudzbe_collection.insertOne(novaNarudzba);
    res.status(201).json({ insertedId: result.insertedId });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});

```

Međutim, provjeru iznad je moguće i skratiti koristeći novi operator `in` koji provjerava je li navedeni ključ prisutan u objektu:

```
key in object;
```

Radi se o modernoj ES6 JavaScript sintaksi koja jako nalikuje Python sintaksi.

Važno! Ovaj operator može se koristiti na ovaj način samo za objekte, ne polja!

Iz toga razloga ne moramo pretvarati objekt u Array ključeva, već možemo direktno provjeriti ključeve:

```

if (!obavezniKljucevi.every(kljuc => kljuc in novaNarudzba)) {
  return res.status(400).json({ error: 'Nedostaju obavezni ključevi' });
}

```

Još moramo provjeriti svaku naručenu pizzu iz polja `narucene_pizze`:

Možemo iterirati kroz polje `narucene_pizze` i za svaku pizzu provjeriti jesu li navedeni ključevi: `naziv`, `količina` i `veličina`. Idemo istom logikom i ove ključeve pohraniti u varijablu:

```

app.post('/narudzbe', async (req, res) => {
  let narudzbe_collection = db.collection('narudzbe');
  let novaNarudzba = req.body;

  let obavezniKljucevi = ['kupac', 'adresa', 'broj_telefona', 'narucene_pizze'];
  // ključevi koje ćemo provjeravati za svaku pizzu (stavku narudžbe)
  let obavezniKljuceviStavke = ['naziv', 'količina', 'velicina'];

  if (!obavezniKljucevi.every(kljuc => kljuc in novaNarudzba)) {
    return res.status(400).json({ error: 'Nedostaju obavezni ključevi' });
  }
  // za svaku stavku narudžbe provjeravamo obavezne ključeve na isti način
  for (let stavka of novaNarudzba.narucene_pizze) {
    if (!obavezniKljuceviStavke.every(kljuc => kljuc in stavka)) {
      return res.status(400).json({ error: 'Nedostaju obavezni ključevi u stavci narudžbe' });
    }
  }

  try {
    let result = await narudzbe_collection.insertOne(novaNarudzba);
    res.status(201).json({ insertedId: result.insertedId });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});

```

Ili možemo ugnijezditi još jednu `every` metodu kako bi izbjegli `for` petlju:

```

app.post('/narudzbe', async (req, res) => {
  let narudzbe_collection = db.collection('narudzbe');
  let novaNarudzba = req.body;


  let obavezniKljucevi = ['kupac', 'adresa', 'broj_telefona', 'narucene_pizze'];
  let obavezniKljuceviStavke = ['naziv', 'količina', 'veličina'];

  if (!obavezniKljucevi.every(kljuc => kljuc in novaNarudzba)) {
    return res.status(400).json({ error: 'Nedostaju obavezni ključevi' });
  }
  // za svaku stavku narudžbe provjeravamo obavezne ključeve, ovaj put ugniježđenom `every`
  metodom
  if (!novaNarudzba.narucene_pizze.every(stavka => obavezniKljuceviStavke.every(kljuc =>
kljuc in stavka))) {
    return res.status(400).json({ error: 'Nedostaju obavezni ključevi u stavci narudžbe'
});
  }

  try {
    let result = await narudzbe_collection.insertOne(novaNarudzba);
    res.status(201).json({ insertedId: result.insertedId });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});

```

Testirajte kod, maknite neki od obaveznih ključeva iz tijela zahtjeva i provjerite je li validacija ispravna.



Slika 20: Postman - Potpuna validacija tijela zahtjeva prilikom dodavanja nove narudžbe u MongoDB bazu podataka.

Provjerite na Atlasu je li nova narudžba dodana.

```
_id: ObjectId('674db5a3a96e615617af91d3')
kupac: "Marko Marić"
adresa: "Vodnjanska 12, 52100 Pula"
broj_telefona: "098 123 456"
narucene_pizze: Array (4)
  0: Object
    naziv: "Capricciosa"
    količina: 2
    veličina: "srednja"
  1: Object
    naziv: "Vegetariana"
    količina: 1
    veličina: "velika"
  2: Object
    naziv: "Capricciosa"
    količina: 1
    veličina: "mala"
  3: Object
```

Slika 21: MongoDB Atlas: U prikazu vidimo klasične JSON oznake (Array, Object), ali i `ObjectId` oznake koje MongoDB automatski dodaje.

Nadogradit ćemo validaciju podataka dodatnim provjerama. Za svaku naručenu pizzu (stavku narudžbe), želimo provjeriti:

1. postoji li pizza u bazi podataka?
2. je li `količina` tipa `integer` i veća od 0?
3. je li `veličina` jedna od triju veličina: `mala`, `srednja`, `velika`?

Dodat ćemo prvo 2. i 3. provjeru, budući da smo to već radili u prethodnim primjerima.

```

app.post('/narudzbe', async (req, res) => {
  let narudzbe_collection = db.collection('narudzbe');
  let novaNarudzba = req.body;

  let obavezniKljucevi = ['kupac', 'adresa', 'broj_telefona', 'narucene_pizze'];
  let obavezniKljuceviStavke = ['naziv', 'količina', 'veličina'];

  if (!obavezniKljucevi.every(kljuc => kljuc in novaNarudzba)) {
    return res.status(400).json({ error: 'Nedostaju obavezni ključevi' });
  }

  if (!novaNarudzba.narucene_pizze.every(stavka => obavezniKljuceviStavke.every(kljuc =>
kljuc in stavka))) {
    return res.status(400).json({ error: 'Nedostaju obavezni ključevi u stavci narudžbe'
});
  }

  // dodajemo dodatne provjere za svaku stavku narudžbe
  // negacija uvjeta: budući da 'every' vraća true ako je za svaki element polja uvjet
ispunjen
  if (
    !novaNarudzba.narucene_pizze.every(stavka => {
      // provjeravamo 3 uvjeta: količina je integer i veća od 0, veličina je jedna od
triju veličina
      return Number.isInteger(stavka.količina) && stavka.količina > 0 && ['mala',
'srednja', 'velika'].includes(stavka.veličina);
    })
  ) {
    return res.status(400).json({ error: 'Neispravni podaci u stavci narudžbe' });
  }

  try {
    let result = await narudzbe_collection.insertOne(novaNarudzba);
    res.status(201).json({ insertedId: result.insertedId });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});

```

Dodat ćemo još provjeru **postoji li pizza u bazi podataka**. To ćemo napraviti tako da za svaku pizzu iz polja `narucene_pizze` provjerimo postoji li pizza s tim nazivom u kolekciji `pizze`.

Prvo dohvaćamo kolekciju `pizze` iz baze:

```

let pizze_collection = db.collection('pizze');

```


Raspakiramo u `Array` sve dokumente iz kolekcije:

```
let dostupne_pizze = await pizze_collection.find().toArray();
```

Dakle, ako je korisnik prosljedio barem jednu pizzu koje nema u bazi podataka, trebamo mu vratiti grešku.

Time-saver hint: Čim vidite izraz “barem jednu” → koristite `Array.some()` metodu

```
if (!novaNarudzba.narucene_pizze.every(stavka => dostupne_pizze.some(pizza => pizza.naziv === stavka.naziv))) {
  return res.status(400).json({ error: 'Odabrali ste pizzu koju nemamo u ponudi' });
}
```



Slika 22: Postman - Slanje zahtjeva s pizzom `Nutella` koja nije u bazi podataka

3.3 PUT i PATCH operacije

Do sad ste naučili da se PUT i PATCH metode koriste za ažuriranje podataka. Razlika između njih je u tome što **PUT metoda zamjenjuje cijeli dokument novim**, dok **PATCH metoda ažurira samo određene dijelove dokumenta** (tj. ključeve JSON objekta).

U kontekstu naše pizzerije, implementirat ćemo PATCH metodu za ažuriranje statusa narudžbe i cijene pizze. PUT metodu koristit ćemo za zamjenu cijelog menija novim.

3.3.1 PATCH /pizze/:naziv

Prvo ćemo definirati PATCH metodu za ažuriranje cijene pizze. Kako smo već definirali GET metodu za dohvaćanje pizze po nazivu, možemo koristiti istu logiku.

```
app.get('/pizze/:naziv', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let naziv_param = req.params.naziv;
  let pizza = await pizze_collection.findOne({ naziv: naziv_param });
  res.status(200).json(pizza);
});
```

Mongo metoda: collection().updateOne()

Za ažuriranje točno jednog dokumenta koristimo collection().updateOne() metodu. Ova metoda očekuje maksimalno **2 obavezna parametra**:

- **filter - obavezni parametar**, definira objekt kojim opisujemo koji podatak želimo ažurirati.
 - Npr. isto kao i kod collection().find() metode, možemo direktno navesti { naziv: 'Capricciosa' }, (ekvivalentno SQL izrazu WHERE naziv = 'Capricciosa').
- **update - obavezni parametar**, kojim definiramo što želimo ažurirati. Ovaj parametar je **objekt koji sadrži ključeve koje želimo ažurirati i nove vrijednosti tih ključeva**.
 - Npr. { \$set: { cijena: 15 } }, (ekvivalentno SQL izrazu SET cijena = 15). Operator koji pišemo na mjestu ključa zove se **update operator**.
- **options - opcionalni parametar**, koji definira dodatne opcije ažuriranja.
 - Npr. { upsert: true }, što znači da će se novi dokument dodati ako ne postoji dokument koji zadovoljava filter.

MongoDB Update operatori

Update operatori ključeva (eng. *Field Update Operators*) su sljedeći:

- **\$set** - postavlja vrijednost ključa na novu vrijednost
- **\$unset** - briše ključ iz dokumenta
- **\$inc** - povećava vrijednost ključa za određeni integer
- **\$mul** - množi vrijednost ključa s određenim brojem
- **\$min** - postavlja vrijednost ključa na novu vrijednost samo ako je postojeća vrijednost manja od nove
- **\$max** - postavlja vrijednost ključa na novu vrijednost samo ako je postojeća vrijednost veća od nove

- `$rename` - preimenuje ključ u dokumentu
- `$currentDate` - postavlja vrijednost ključa na trenutni datum
- ima ih još...

Ispred update operatora uvijek ide znak "\$"

Sintaksa:

```
db.collection('naziv_kolekcije').updateOne({ filter }, { update }); // gdje su filter i update objekti
```

Primjeri korištenja update operatora i `collection().updateOne()` metode:

1. Želimo zamijeniti cijenu pizze `Capricciosa` s novom cijenom 15:

```
// update operator
{
  $set: {
    cijena: 15;
  }
}

// updateOne() metoda
collection('naziv_kolekcije').updateOne({ naziv: 'Capricciosa' }, { $set: { cijena: 15 } });
```

2. Želimo zamijeniti naziv pizze `Capricciosa` s novim nazivom `Capricciosa Supreme`:

```
// update operator
{
  $set: {
    naziv: 'Capricciosa Supreme';
  }
}

// updateOne() metoda
collection('naziv_kolekcije').updateOne({ naziv: 'Capricciosa' }, { $set: { naziv: 'Capricciosa Supreme' } });
```

3. Želimo povećati cijenu pizze `Capricciosa` za 2 eura:

```
// update operator
{
  $inc: {
    cijena: 2;
  }
}

// updateOne() metoda
collection('naziv_kolekcije').updateOne({ naziv: 'Capricciosa' }, { $inc: { cijena: 2 } });
```

4. Želimo obrisati cijenu pizze Capricciosa:

```
// update operator
{
  $unset: {
    cijena: '';
  }
}

// updateOne() metoda
collection('naziv_kolekcije').updateOne({ naziv: 'Capricciosa' }, { $unset: { cijena: '' } });
```

5. Želimo postaviti cijenu pizze Capricciosa na 10 eura, ali samo ako je trenutna cijena manja od 10 eura:

```
// update operator
{
  $min: {
    cijena: 10;
  }
}

// updateOne() metoda
collection('naziv_kolekcije').updateOne({ naziv: 'Capricciosa' }, { $min: { cijena: 10 } });
```

6. Želimo postaviti cijenu pizze Margherita na 20 eura, ali samo ako je trenutna cijena veća od 20 eura:

```
// update operator
{
  $max: {
    cijena: 20;
  }
}

// updateOne() metoda
collection('naziv_kolekcije').updateOne({ naziv: 'Margherita' }, { $max: { cijena: 20 } });
```

7. Želimo preimenovati ključ cijena u cijena_eur za pizzu Quattro Stagioni:

```
// update operator
{
  $rename: {
    cijena: 'cijena_eur';
  }
}

// updateOne() metoda
collection('naziv_kolekcije').updateOne({ naziv: 'Quattro Stagioni' }, { $rename: { cijena: 'cijena_eur' } });
```

8. Želimo postaviti ključ datum_dodavanja na trenutni datum za pizzu Vegetariana:

```
// update operator
{
  $currentDate: {
    datum_dodavanja: {
      $type: 'date';
    }
  }
}


// updateOne() metoda
collection('naziv_kolekcije').updateOne({ naziv: 'Vegetariana' }, { $currentDate: { datum_dodavanja: { $type: 'date' } } });
```

Dakle, endpoint za ažuriranje cijene pizze ćemo definirati koristeći \$set update operator (radi se o najčešće korištenom operatoru):

```
app.patch('/pizze/:naziv', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let naziv_param = req.params.naziv;
  let novaCijena = req.body.cijena;

  try {
    let result = await pizze_collection.updateOne({ naziv: naziv_param }, { $set: { cijena: novaCijena } });
    res.status(200).json({ modifiedCount: result.modifiedCount });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});
```

Primjer slanja zahtjeva. Povećat ćemo cijenu pizze *Capricciosa* na 13 eura:



Slika 23: Postman - Ažuriranje cijene pizze *Capricciosa* na 13 eura putem PATCH metode.

Kao odgovor dobivamo **broj ažuriranih dokumenata** (`modifiedCount : 1`).

Ovaj podatak možemo iskoristiti kako bi se uvjerali u ispravnost ažuriranja te informaciju proslijediti klijentu, ali i dodati provjeru ako pizza nije pronađena (`modifiedCount == 0`)

```
app.patch('/pizze/:naziv', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let naziv_param = req.params.naziv;
  let novaCijena = req.body.cijena;

  try {
    let result = await pizze_collection.updateOne({ naziv: naziv_param }, { $set: {
cijena: novaCijena } });

    if (result.modifiedCount === 0) {
      return res.status(404).json({ error: 'Pizza nije pronađena' });
    }

    res.status(200).json({ modifiedCount: result.modifiedCount });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});
```

3.3.2 PATCH `/narudzbe/:id`

Na isti način ćemo definirati PATCH metodu za ažuriranje statusa narudžbe.

Prvo ćemo definirati jednostavni GET `/narudzbe` za dohvaćanje svih narudžbi.

```
app.get('/narudzbe', async (req, res) => {
  let narudzbe_collection = db.collection('narudzbe');
  let narudzbe = await narudzbe_collection.find().toArray();

  if (narudzbe.length === 0) {
    return res.status(404).json({ error: 'Nema narudžbi' });
  }

  res.status(200).json(narudzbe);
});
```

Kod filtera `collection().findOne()` metode koristimo `ObjectId` konstruktor kako bi pretvorili string ID iz URL parametra u MongoDB `ObjectId` tip podatka.

Ovaj konstruktor je potrebno učitati na početku datoteke:

```
import { ObjectId } from 'mongodb';
```

Dakle, metoda za dohvaćanje jedne narudžbe po ID-u bila bi sljedeća:

```
app.get('/narudzbe/:id', async (req, res) => {
  let narudzbe_collection = db.collection('narudzbe');
  let id_param = req.params.id;
  let narudzba = await narudzbe_collection.findOne({ _id: new ObjectId(id_param) }); //
  instanciramo objekt ObjectId

  if (!narudzba) {
    return res.status(404).json({ error: 'Narudžba nije pronađena' });
  }

  res.status(200).json(narudzba);
});
```

The screenshot shows a REST client interface with the following details:

- Method:** GET
- URL:** http://localhost:3000/narudzbe/674dbb61cd85b5d3bd083714
- Status:** 200 OK
- Size:** 377 Bytes
- Time:** 43 ms
- Response:**

```
{
  "_id": "674dbb61cd85b5d3bd083714",
  "kupac": "Marko Marić",
  "adresa": "Vodnjanska 12, 52100 Pula",
  "broj_telefona": "098 123 456",
  "narucene_pizze": [
    {
      "naziv": "Margherita",
      "količina": 2,
      "veličina": "srednja"
    },
    {
      "naziv": "Vegetariana",
      "količina": 1,
      "veličina": "velika"
    },
    {
      "naziv": "Capricciosa",
      "količina": 1,
      "veličina": "mala"
    },
    {
      "naziv": "Šunka sir",
      "količina": 3,
      "veličina": "srednja"
    }
  ]
}
```

Slika 24: Postman - Dohvaćanje narudžbe po ID-u putem GET metode. ID smo kopirali ručno iz prethodnog odgovora (možemo i direktno iz Atlasa)

Kako bismo sad ažurirali status narudžbe, koristit ćemo PATCH metodu i `updateOne()` metodu sa `$set` operatorom. **Bez obzira što ovog polja trenutno nema u narudžbi, on će se automatski dodati.**

```
app.patch('/narudzbe/:id', async (req, res) => {
  let narudzbe_collection = db.collection('narudzbe');
  let id_param = req.params.id;
  let noviStatus = req.body.status; // npr. 'isporučeno', 'u pripremi', 'otkazano'

  try {
    let result = await narudzbe_collection.updateOne({ _id: new ObjectId(id_param) }, {
      $set: { status: noviStatus } });

    if (result.modifiedCount === 0) {
      return res.status(404).json({ error: 'Narudžba nije pronađena' });
    }

    res.status(200).json({ modifiedCount: result.modifiedCount });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});
```

3.3.3 PUT /pizze

Što ako želimo zamijeniti cijeli meni s pizzama odjednom. Primjerice, imamo korisničko sučelje na strani klijenta gdje možemo dodati, ažurirati i obrisati pizze iz menija. **Rezultat tih akcija je novi meni koji sadrži sve pizze** (odnosno JSON koji sadrži sve pizze).

Takav JSON izgledao bi otprilike ovako:

```
[
  {
    "naziv": "Margherita",
    "cijena": 10.5
  },
  {
    "naziv": "Napolitana",
    "cijena": 12.5
  },
  {
    "naziv": "Funghi",
    "cijena": 11.5
  },
  {
    "naziv": "Capricciosa",
    "cijena": 13.5
  },
  {
    "naziv": "Vegetariana",
    "cijena": 14.5
  },
  {
    "naziv": "Šunka sir",
    "cijena": 15.5
  },
  {
    "naziv": "Quattro Stagioni",
    "cijena": 16.5
  },
  {
    "naziv": "Fantasia",
    "cijena": 17.5
  }
]
```

Kada bi pizze dodavali ručno, trebali bi za svaki zapis pozvati postojeći endpoint `POST /pizze`.

Na frontendu bi to, koristeći `Axios` biblioteku, izgledalo ovako:

```
// gdje su pizze polje objekata prikazano iznad
for (let pizza of pizze) {
  axios
    .post('http://localhost:3000/pizze', pizza)
    .then(response => console.log(response.data))
    .catch(error => console.error(error));
}

// ili koristeći HTTP PUT metodu za zamjenu cijelog menija

axios
  .put('http://localhost:3000/pizze', pizze)
  .then(response => console.log(response.data))
  .catch(error => console.error(error));
```

Definirat ćemo endpoint `PUT /pizze` koji će zamijeniti cijeli meni s pizzama novim menijem odjednom.

Mongo metoda: `collection().insertMany()`

Metoda `collection().insertMany()` koristi se za dodavanje više dokumenata odjednom u kolekciju. Ova metoda očekuje **1 obavezni parametar**:

- **documents - obavezni parametar**, polje objekata koje želimo dodati u kolekciju.
 - Npr. `[ { naziv: 'Margherita', cijena: 10.5 }, { naziv: 'Napolitana', cijena: 12.5 } ]`.
Navedeno je ekvivalentno SQL izrazu: `INSERT INTO pizze (naziv, cijena) VALUES ('Margherita', 10.5), ('Napolitana', 12.5);`.
- **options - opcionalni parametar**, koji definira dodatne opcije dodavanja.
 - Npr. `{ ordered: false }`, što znači da će se svi dokumenti dodati. Po *defaultu*, ova metoda prestaje dodavati ako naiđe na grešku, parametrom `ordered: false` to se može spriječiti.

Sintaksa:

```
db.collection('naziv_kolekcije').insertMany([ dokument1, dokument2, ... ]); // samo
'documents' parametar
```

Primjer korištenja `insertMany()` metode endpoint `PUT /pizze`:

```

app.put('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let noviMeni = req.body;

  try {
    let result = await pizze_collection.insertMany(noviMeni); // dodajemo novi meni
    (polje objekata)
    res.status(200).json({ insertedCount: result.insertedCount });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});

```

Međutim ova metoda će sad samo dodati nove pizze u kolekciju, **a ne zamijeniti cijeli meni.**

Ovo možemo riješiti na dva načina:

1. **obrisati cijelu kolekciju** te zatim pozvati `collection().insertMany()` metodu koja će stvoriti novu kolekciju i ubaciti sve pizze
2. **obrisati sve pizze** iz kolekcije metodom `collection().deleteMany()` te zatim pozvati `insertMany()` metodu

Kako bismo obrisali cijelu kolekciju, možemo koristiti metodu `collection().drop()`:

```

await pizze_collection.drop();

```

```

// 1. način
app.put('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let noviMeni = req.body;


  try {
    await pizze_collection.drop(); // brišemo cijelu kolekciju
    let result = await pizze_collection.insertMany(noviMeni);
    res.status(200).json({ insertedCount: result.insertedCount });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});

```

Ili koristimo metodu `deleteMany()`, bez da brišemo cijelu kolekciju (što je sigurnije):

```
// 2. način
app.put('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let noviMeni = req.body;

  try {
    await pizze_collection.deleteMany({}); // brišemo sve pizze iz kolekcije
    let result = await pizze_collection.insertMany(noviMeni);
    res.status(200).json({ insertedCount: result.insertedCount });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});
```



Slika 25: Postman - Zamjena cijelog menija s novim menijem putem PUT metode.

3.4 DELETE operacija

Na kraju CRUD operacija, pogledat ćemo još jednu metodu - `DELETE`. Ova metoda koristi se za brisanje podataka iz baze podataka.

Moguće je brisati pojedinačni podatak, više podataka prema nekom filteru ili cijelu kolekciju (kao što ste već vidjeli iznad).

Pokazat ćemo primjer brisanja pizze iz menija prema nazivu.

3.4.1 DELETE /pizze/:naziv

Mongo metoda: `collection().deleteOne()`

Koristit ćemo metodu `deleteOne()` koja briše točno jedan dokument iz kolekcije (**prvi koji pronađe**). Ova metoda očekuje **1 obavezni parametar**:

- filter - obavezni parametar**, definira filter objekt koji opisuje podatak koji želimo obrisati, isto kao i kod `collection().find()` metode. Npr. `{ naziv: 'Capricciosa' }`, (ekvivalentno SQL izrazu `WHERE naziv = 'Capricciosa'`).


Sintaksa:

```
db.collection('naziv_kolekcije').deleteOne({ filter });
```

```
app.delete('/pizze/:naziv', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let naziv_param = req.params.naziv;

  try {
    let result = await pizze_collection.deleteOne({ naziv: naziv_param }); // brišemo pizzu prema nazivu
    res.status(200).json({ deletedCount: result.deletedCount });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});
```

Primjer brisanja pizze `Capricciosa` iz menija:



Slika 26: Postman - Brisanje pizze `Capricciosa` iz menija putem `DELETE` metode.

Mongo metoda: `collection().deleteMany()`

Ako želimo obrisati više dokumenata iz kolekcije, koristimo metodu `deleteMany()`. Ova metoda očekuje **1 obavezni parametar**:

- **filter** - **obavezni parametar**, definira koji dokumenti želimo obrisati, isto kao i kod `collection().find()` metode.
 - Npr. `{ cijena: { $gte: 15 } }`, (ekvivalentno SQL izrazu `WHERE cijena >= 15`). Ako navedemo samo `{}`, obrisat će se svi dokumenti iz kolekcije.

Sintaksa:

```
db.collection('naziv_kolekcije').deleteMany({ filter }); //
```

```
app.delete('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');

  try {
    let result = await pizze_collection.deleteMany({}); // brišemo sve pizze iz kolekcije
    res.status(200).json({ deletedCount: result.deletedCount });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});
```

4. Agregacija podataka

Agregacija podataka odnosi se na obradu podataka na temelju nekog kriterija. Krenut ćemo s primjerom filtriranja podataka koji smo već koristili u prethodnim primjerima. Međutim, nadograđujemo stvari na način da ćemo se prisjetiti `query` parametra HTTP zahtjeva te ih kombinirati s MongoDB upitima. Osim toga, agregacija predstavlja i složenije operacije poput grupiranja, sortiranja i računanja statistika nad podacima (npr. zbrajanje, prosjek, maksimum, minimum, brojanje, itd.).

4.1 Filtriranje podataka

Prisjetimo se `query` parametra (parametri upita):

- rekli smo da ih definiramo unutar URL-a nakon znaka `?`
- svaki `query` parametar sastoji se od ključa i vrijednosti, npr. `?ključ1=vrijednost1`
- više `query` parametara odvajamo znakom `&`, npr. `?ključ1=vrijednost1&ključ2=vrijednost2`

Primjer URL-a s `query` parametrima:

```
http://localhost:3000/pizze?cijena=10&naziv=Capricciosa
```

Kod definicije endpointa, **ove parametre ne navodimo direktno u URL-u**, već ih dohvaćamo iz `req.query` objekta.

Vidjeli smo kako filtrirati, točnije pretraživati, određeni dokument u kolekciji koristeći `collection().find()` metodu:

```
let pizze = await pizze_collection.find({ naziv: 'Capricciosa' }).toArray(); // pronadi pizzu  
čiji je naziv 'Capricciosa'
```

Rekli smo da, ako se radi uvijek o jednom dokumentu, koristimo `findOne()` metodu:

```
let pizza = await pizze_collection.findOne({ naziv: 'Capricciosa' }); // pronadi pizzu čiji  
je naziv 'Capricciosa'
```

Kako bismo pronašli sve pizze čija je cijena jednaka 10, pišemo sljedeći kod:

```
let pizze = await pizze_collection.find({ cijena: 10 }).toArray(); // pronadi sve pizze čija  
je cijena 10
```

Međutim, kako bismo pronašli sve pizze gdje je cijena minimalno 10, ili maksimalno 15.

Koristimo sljedeće MongoDB operatore usporedbe (eng. *Comparison Operators*):

- `$gte` - veće ili jednako (greater than or equal)
- `$lte` - manje ili jednako (less than or equal)
- `$gt` - veće (greater than)
- `$lt` - manje (less than)
- `$eq` - jednako (equal)
- `$ne` - nije jednako (not equal)

Kao i kod operatora usporedbe, i ovdje ispred ide znak "\$"

Primjeri korištenja *comparison operator* i `find()` metode:

1. Želimo pronaći sve pizze čija je cijena veća ili jednaka 10:

```
// comparison operator  
{  
  cijena: {  
    $gte: 10;  
  }  
}  
  
// find() metoda  
collection('naziv_kolekcije').find({ cijena: { $gte: 10 } });
```

2. Želimo pronaći sve pizze čija je cijena manja ili jednaka 15:

```
// comparison operator
{
  cijena: {
    $lte: 15;
  }
}

// find() metoda
collection('naziv_kolekcije').find({ cijena: { $lte: 15 } });
```

3. Želimo pronaći sve pizze čija je cijena veća od 10 i manja od 15:

```
// comparison operatori
{
  cijena: {
    $gt: 10,
    $lt: 15;
  }
}

// find() metoda
collection('naziv_kolekcije').find({ cijena: { $gt: 10, $lt: 15 } });
```

4. Želimo pronaći sve pizze čija je cijena različita od 5:

```
// comparison operator
{
  cijena: {
    $ne: 5;
  }
}

// find() metoda
collection().find({ cijena: { $ne: 5 } });
```

4.1.1 GET /pizze?query

Kombinirat ćemo ova dva pristupa (*query* parametre i MongoDB operatore usporedbe) kako bismo filtrirali pizze prema cijeni.

Očekuje se da će korisnik poslati *query* parametar `cijena` u URL-u, npr. `http://localhost:3000/pizze?cijena=10`.

```

app.get('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let cijena_query = req.query.cijena;

  try {
    let pizze = await pizze_collection.find({ cijena: Number(cijena_query) }).toArray();
    // provjerava se točno podudaranje cijene
    res.status(200).json(pizze);
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});

```

U redu, ali ako sad pošaljemo zahtjev bez *query* parametra `cijena`, dobit ćemo prazan Array. Moramo obraditi slučaj gdje klijent nije poslao *query* parametar.


```

app.get('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');
  let cijena_query = req.query.cijena;

  if (!cijena_query) {
    let pizze = await pizze_collection.find().toArray(); // dohvaćamo sve pizze
    return res.status(200).json(pizze);
  }

  try {
    let pizze = await pizze_collection.find({ cijena: Number(cijena_query) }).toArray();
    // provjerava se točno podudaranje cijene
    res.status(200).json(pizze);
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});


```



Slika 27: Postman - Dohvaćanje svih pizza čija je cijena jednaka 10 putem GET metode s query parametrom.

Ako bismo htjeli pronaći sve pizze čija je cijena veća ili jednaka 10, koristili bismo `$gte` operator:

```
let pizze = await pizze_collection.find({ cijena: { $gte: Number(cijena_query) }
}).toArray(); // dohvaćamo pizze čija je cijena veća ili jednaka od cijena_query
```



Slika 28: Postman - Dohvaćanje svih pizza čija je cijena veća ili jednaka 10 putem GET metode s query parametrom.

4.2 Ažuriranje svih podataka gdje je uvjet zadovoljen

Što ako želimo koristiti agregaciju podataka za ažuriranje svih dokumenata u kolekciji gdje je uvjet zadovoljen, a ne sam za njihovo dohvaćanje?

Kako bismo povećali cijenu svih pizza čija je cijena manja od 15 za 2 eura?

Mongo metoda: `collection().updateMany()`

Koristit ćemo metodu `updateMany()` koja radi na isti način kao i `updateOne()`, ali ažurira sve dokumente koji zadovoljavaju uvjet. Ova metoda prima **2 obavezna parametra**:

- **filter - obavezni parametar**, definira filter objekt koji predstavlja one dokumente želimo ažurirati, isto kao i kod `collection().find()` metode.
 - Npr. `{ cijena: { $lt: 15 } }`, (ekvivalentno SQL izrazu `WHERE cijena < 15`).
- **update - obavezni parametar**, kojim definiramo što želimo ažurirati. Ovaj parametar je JSON objekt koji sadrži ključeve koje želimo ažurirati i nove vrijednosti tih ključeva.
 - Npr. `{ $inc: { cijena: 2 } }`, (ekvivalentno SQL izrazu `SET cijena = cijena + 2`).
- **options - opcionalni parametar**, koji definira dodatne opcije ažuriranja.
 - Npr. `{ upsert: true }`, što znači da će se novi dokument dodati iako ne postoji dokument koji zadovoljava filter.

Sintaksa:

```
db.collection('naziv_kolekcije').updateMany({ filter }, { update }); // {filter}, {update}
obavezni parametri
```

Primjerice: želimo povećati cijenu svih pizza čija je cijena manja od 15 za 2 eura:

```
let result = await pizze_collection.updateMany({ cijena: { $lt: 15 } }, { $inc: { cijena: 2 } }); // {filter}, {update}
```

- za filtriranje smo koristili `$lt` **operator usporedbe**
- za ažuriranje smo koristili `$inc` **update operator**

Ili, recimo da želimo postaviti cijenu svih pizza čija je cijena veća od 15 na 20 eura:

```
let result = await pizze_collection.updateMany({ cijena: { $gt: 15 } }, { $set: { cijena: 20 } }); // {filter}, {update}
```

- za filtriranje smo koristili `$gt` **operator usporedbe**
- za ažuriranje smo koristili `$set` **update operator**

Prema tome, definirat ćemo endpoint koji će povećati cijenu svih pizza čija je cijena manja od 15 za 2 eura. Kako ažuriramo djelomične podatke (samo tamo gdje je uvjet zadovoljen, a ne cijeli dokument), koristit ćemo PATCH metodu.

```
app.patch('/pizze', async (req, res) => {
  let pizze_collection = db.collection('pizze');

  try {
    let result = await pizze_collection.updateMany({ cijena: { $lt: 15 } }, { $inc: { cijena: 2 } }); // povećaj cijenu svih pizza čija je cijena manja od 15 za 2 eura
    res.status(200).json({ modifiedCount: result.modifiedCount });
  } catch (error) {
    console.log(error.errorResponse);
    res.status(400).json({ error: error.errorResponse });
  }
});
```

4.3 Sortiranje podataka

Sortiranje podataka možemo obaviti koristeći `collection().sort()` metodu. Ova metoda očekuje **1 obavezni parametar**:

- `sort` - **obavezni parametar**, definira po kojem kriteriju želimo sortirati podatke. Npr. `{ cijena: 1 }`, (sortira po cijeni od najmanje prema najvećoj). Ako želimo sortirati od najveće prema najmanje, koristimo `{ cijena: -1 }`.

Primjer korištenja `sort()` metode:

```
let pizze = await pizze_collection.find().sort({ cijena: 1 }).toArray(); // sortira pizze po cijeni od najmanje prema najvećoj
```

Možemo navesti i više polja po kojima želimo sortirati.

Primjer, želimo sortirati po nazivu pizze od A do Z, a zatim po cijeni od najveće prema najmanjoj:

```
let pizze = await pizze_collection.find().sort({ naziv: 1, cijena: -1 }).toArray(); //  
sortira pizze po nazivu od A do Z, a zatim po cijeni od najveće prema najmanjoj
```

4.3.1 GET /pizze?sort


Dodat ćemo ova dva uvjeta kao `query` parametre u URL-u:

- `cijena` - za sortiranje po cijeni
- `naziv` - za sortiranje po nazivu

Vrijednosti parametra mogu biti upravo `1` ili `-1`.

```
app.get('/pizze', async (req, res) => {  
  let pizze_collection = db.collection('pizze');  
  let cijena_query = req.query.cijena;  
  let naziv_query = req.query.naziv;  
  
  try {  
    let pizze = await pizze_collection  
      .find()  
      .sort({ cijena: Number(cijena_query), naziv: Number(naziv_query) })  
      .toArray(); // sortira pizze po cijeni i nazivu  
    res.status(200).json(pizze);  
  } catch (error) {  
    console.log(error.errorResponse);  
    res.status(400).json({ error: error.errorResponse });  
  }  
});
```

Primjer sortiranja po nazivu od A do Z, a zatim po cijeni od najveće prema najmanjoj:



Slika 29: Postman - Dohvaćanje svih pizza sortiranih po nazivu od A do Z, a zatim po cijeni od najveće prema najmanjoj putem GET metode s query parametrima.

4.4 Složena agregacija podataka metodom `aggregate()`

Za kraj ćemo pogledati kako možemo koristiti `aggregate()` metodu za složenije agregacije podataka, primjerice kada želimo odraditi više operacija nad podacima prije nego što ih dohvatimo.

Ova metoda dozvoljava složene operacije, poput filtriranja, sortiranja, grupiranja, računanja itd.

Sintaksa:

```
db.collection('naziv_kolekcije').aggregate([ { operacija1 }, { operacija2 }, {operacija3} ...
]);
```

- gdje operacija može biti bilo koja MongoDB operacija. Ove operacije često nazivamo i `pipeline` operacijama ili `pipeline stages`.

U MongoDB, pipeline operacije se izvršavaju redom, gdje je **izlaz jedne operacije ulaz sljedeće operacije**.

Operacije, kao i sve do sad u MongoDB, koriste JSON sintaksu.

1. `$match` - filtrira dokumente **prema nekom uvjetu**, kao i kod `find()` metode.

```

{
  $match: { cijena: { $lt: 15 } } // pronadi sve pizze čija je cijena manja od 15
}

{
  $match: { naziv: 'Capricciosa' } // pronadi pizzu čiji je naziv 'Capricciosa'
}

{
  $match: { cijena: { $gte: 10, $lte: 15 } } // pronadi sve pizze čija je cijena između 10 i 15
}

```

2. **\$group** - grupira dokumente **prema nekom polju** i specificiranoj funkciji agregacije (npr. `$sum`, `$avg`, `$min`, `$max`).

```

{
  $group: {
    _id: '$category', // grupiraj po kategoriji pizze (npr. 's mesom', 'vegetarijanske', 'slatke')
    broj_pizza: { $sum: 1 } // za svaku kategoriju, izracunaj broj pizza
  }
}

{
  $group: {
    _id: '$category', // grupiraj po kategoriji pizze
    prosjecna_cijena: { $avg: '$cijena' } // za svaku kategoriju, izracunaj prosjecnu cijenu pizza
  }
}

```

3. **\$sort** - sortira dokumente **prema nekom polju**.

```

{
  $sort: { cijena: 1 } // sortiraj pizze po cijeni od najmanje prema najvećoj
}

{
  $sort: { naziv: -1 } // sortiraj pizze po nazivu od Z do A
}

```

4. **\$limit** - ograničava broj rezultata

```

{
  $limit: 5; // ograniči rezultate na prvih 5
}

```

5. **\$skip** - preskače određeni broj rezultata

```
{
  $skip: 5; // preskoči prvih 5 rezultata
}
```

6. **\$lookup** - spaja dokumente iz druge kolekcije koristeći *left outer join*

```
{
  $lookup: {
    from: 'kolekcija2', // ime druge kolekcije
    localField: 'id', // polje iz trenutne kolekcije
    foreignField: 'id', // polje iz druge kolekcije
    as: 'ime_polja' // ime polja u kojem će se spremiti rezultati
  }
}
```

I tako dalje, ima ih jako puno. Cijeli popis možete pronaći na [sljedećoj poveznici](#).

Kako ovo koristiti u praksi?

Primjerice, ako želimo pronaći sve pizze čija je cijena manja od 15 i sortirati ih po cijeni od najmanje prema najvećoj, pišemo sljedeći aggregate upit:

```
let pizze = await pizze_collection.aggregate([
  { $match: { cijena: { $lt: 15 } } },
  { $sort: { cijena: 1 } }
]);
```

Ako želimo pronaći sve pizze čija je cijena manja od 15, sortirati ih po cijeni od najmanje prema najvećoj i ograničiti rezultate na prvih 5:

```
let pizze = await pizze_collection.aggregate([
  { $match: { cijena: { $lt: 15 } } },
  { $sort: { cijena: 1 } },
  { $limit: 5 }
]);
```

Ako želimo pronaći sve pizze čija je cijena manja od 15, sortirati ih po cijeni od najmanje prema najvećoj, ograničiti rezultate na prvih 5, ali preskočiti prva 2:

```
let pizze = await pizze_collection.aggregate([
  { $match: { cijena: { $lt: 15 } } },
  { $sort: { cijena: 1 } },
  { $skip: 2 },
  { $limit: 5 }
]);
```

5. MongoDB - TL;DR

MongoDB je dokumentno-orijentirana baza podataka koja koristi JSON-like dokumente za pohranu podataka.

Implementacija Drivera za Node.js je `mongodb` paket. **Implementacija je ogromna** i ima jako puno razrađenih metoda, operatora i ostalih funkcionalnosti.

Dokumentacija: <https://www.mongodb.com/docs/>.

Važno je razumjeti osnovni princip rada svih metoda u MongoDB-u, **a to je korištenje JSON strukture** za definiranje filtera, ažuriranja, sortiranja, grupiranja i ostalih operacija. U usporedbi s relacijskom bazom, gdje pišemo SQL upite, u MongoDB-u koristimo isključivo gotove metode s **JSON strukturom kao parametrima** (osim ako ne koristite *mongoose* ili neki drugi **ORM**-like Mongo wrapper).

U ovoj skripti smo pokrili **CRUD operacije, agregaciju podataka, složene upite, sortiranje, grupiranje, ažuriranje i brisanje podataka**, međutim ima tu još toga jako puno. Dovoljno je dugačka ova skripta, a ista može poslužiti kao dokumentacija i podsjetnik za rad s Mongom u budućnosti.

5.1 Spajanje na bazu podataka

Spajanje na bazu podataka praktično je definirati unutar vanjske datoteke, npr. `db.js`:

- želimo odvojiti logiku spajanja na bazu podataka od ostatka Express aplikacije
- funkcija `connectToDatabase()` vraća `db` objekt koji koristimo za rad s bazom podataka na više mjesta unutar aplikacije - ne želimo ponavljati kod za spajanje

```
// db.js
import { MongoClient } from 'mongodb';
import { config } from 'dotenv';

config();

let mongoURI = process.env.MONGO_URI;
let db_name = process.env.MONGO_DB_NAME;

async function connectToDatabase() {
  try {
    const client = new MongoClient(mongoURI);
    await client.connect();
    console.log('Uspješno spajanje na bazu podataka');
    let db = client.db(db_name);

    return db;
  } catch (error) {
    console.error('Greška prilikom spajanja na bazu podataka', error);
    throw error;
  }
}

export { connectToDatabase };
```

Zatim možemo definirati `db` objekt unutar bilo koje datoteke, najčešće je to `index.js` (ali može biti i unutar bilo kojeg Routera ili `sl`):

```
// index.js

import express from 'express';
import { connectToDatabase } from './db.js';

const app = express();

let db = await connectToDatabase();

app.listen(3000, () => {
  console.log('Server pokrenut na portu 3000');
});
```

- Kolekciju dohvaćamo koristeći `db.collection('naziv_kolekcije')` metodu.
- Novu kolekciju možemo napraviti koristeći `db.createCollection('naziv_kolekcije')`
- Koristeći `db.listCollections()` možemo dohvatiti sve kolekcije u bazi podataka
- Koristeći `db.dropCollection('naziv_kolekcije')` možemo obrisati kolekciju
- Indekse možemo raditi u kodu, koristeći `db.collection('naziv_kolekcije').createIndex({ ključ: vrijednost })`, ili kroz GUI

- Možemo dohvatiti sve indekse koristeći `db.collection.getIndexes()`
- Isto tako, možemo obrisati indeks koristeći `db.collection.dropIndex({ kljuc: vrijednost })`

5.2 CRUD operacije

- **Create**
 - `collection().insertOne(document)` - **dodavanje jednog dokumenta** `document` u kolekciju
 - `collection().insertMany(documents)` - **dodavanje više dokumenata** `documents` u kolekciju
- **Read**
 - `collection().find(filter, projection)` - **dohvaćanje svih dokumenata koji zadovoljavaju** `filter`, vraća `FindCursor`. `projection` je opcionalni parametar koji definira koja polja želimo dohvatiti
 - `collection().findOne(filter, projection)` - **dohvaćanje prvog dokumenta koji zadovoljava** `filter`, vraća `Promise`. `projection` je opcionalni parametar koji definira koja polja želimo dohvatiti
 - `cursor.toArray()` - pretvaranje `FindCursor` objekta u polje dokumenata, vraća `Promise`
 - `aggregate([ pipeline ])` - **složena agregacija podataka**, gdje `pipeline` predstavlja niz operacija koje želimo izvršiti
 - `collection().countDocuments(filter)` - **brojanje dokumenata koji zadovoljavaju** `filter`, vraća `Promise`
- **Update**
 - `collection().updateOne(filter, update)` - **ažuriranje prvog dokumenta koji zadovoljava** `filter` s novim podacima `update`
 - `collection().updateMany(filter, update)` - **ažuriranje svih dokumenata koji zadovoljavaju** `filter` s novim podacima `update`
 - `collection().replaceOne(filter, replacement)` - **zamjena prvog dokumenta koji zadovoljava** `filter` s novim dokumentom `replacement`
- **Delete**
 - `collection().deleteOne(filter)` - **brisanje prvog dokumenta koji zadovoljava** `filter`
 - `collection().deleteMany(filter)` - **brisanje svih dokumenata koji zadovoljavaju** `filter`

5.3 MongoDB operatori

MongoDB sadrži implementiranu veliku količinu operatora za razne operacije, poput usporedbe, logičkih operacija, ažuriranja, grupiranja, sortiranja itd.

5.3.1 Operatori ažuriranja (eng. Update operators)

Update operator	Sintaksa	Primjer	Objašnjenje
\$set	<pre>{ \$set: { key: value }}</pre>	<pre>{ \$set: { age: 30 } }</pre>	Postavlja vrijednost ključa <code>key</code> u dokumentu na vrijednost <code>value</code> . Ako ključ ne postoji, dodaje ključ.
\$unset	<pre>{ \$unset: { key: "" }}</pre>	<pre>{ \$unset: { age: "" } }</pre>	Briše vrijednost ključa <code>key</code> u dokumentu.
\$inc	<pre>{ \$inc: { key: value }}</pre>	<pre>{ \$inc: { age: 1 } }</pre>	Inkrementira vrijednost ključa <code>key</code> za definiranu vrijednost <code>value</code> .
\$mul	<pre>{ \$mul: { key: value }}</pre>	<pre>{ \$mul: { price: 1.1 } }</pre>	Množi vrijednost ključa za definiranu vrijednost.
\$rename	<pre>{ \$rename: { oldKey: newKey }}</pre>	<pre>{ \$rename: { name: "fullName" }}</pre>	Preimenuje ključ <code>oldKey</code> u ključ <code>newKey</code> .
\$min	<pre>{ \$min: { key: value }}</pre>	<pre>{ \$min: { age: 18 } }</pre>	Postavlja vrijednost ključa <code>key</code> na novu vrijednost <code>value</code> samo ako je postojeća vrijednost manja od nove.
\$max	<pre>{ \$max: { key: value }}</pre>	<pre>{ \$max: { age: 65 } }</pre>	Postavlja vrijednost ključa <code>key</code> na novu vrijednost <code>value</code> samo ako je postojeća vrijednost veća od nove.

Update operator	Sintaksa	Primjer	Objašnjenje
\$currentDate	<pre>{ \$currentDate: { key: type } }</pre>	<pre>{ \$currentDate: { lastModified: { \$type: "timestamp" } } }</pre>	Postavlja vrijednost ključa <code>key</code> na trenutni datum (timestamp).
\$push	<pre>{ \$push: { key: value } }</pre>	<pre>{ \$push: { tags: "newTag" } }</pre>	Ako je ključ <code>key</code> polje, dodaje u njega vrijednost <code>value</code> . Ako polje ne postoji, dodaje ga.
\$pop	<pre>{ \$pop: { key: 1 or -1 } }</pre>	<pre>{ \$pop: { tags: -1 } }</pre>	Briše prvi (-1) ili zadnji (1) element unutar polja.
\$pull	<pre>{ \$pull: { key: condition } }</pre>	<pre>{ \$pull: { tags: "oldTag" } }</pre>	Briše sve elemente polja koji su istiniti za dani <code>condition</code> .
\$addToSet	<pre>{ \$addToSet: { key: value } }</pre>	<pre>{ \$addToSet: { tags: "uniqueTag" } }</pre>	Dodaje vrijednost <code>value</code> u polje samo ako vrijednost već ne postoji.
\$each	<pre>{ \$push: { key: { \$each: values }}} }</pre>	<pre>{ \$push: { tags: { \$each: ["tag1", "tag2"] } } }</pre>	Dodaje više vrijednosti <code>values</code> u polje. Često se koristi u kombinaciji s <code>\$push</code> .

5.3.2 Operatori usporedbe (eng. Comparison operators)

Comparison operator	Sintaksa	Primjer	Objašnjenje
\$eq	<code>{ key: { \$eq: value } }</code>	<code>{ age: { \$eq: 25 } }</code>	Podudara dokumente gdje je vrijednost ključa <code>key</code> jednaka vrijednosti <code>value</code> .
\$ne	<code>{ key: { \$ne: value } }</code>	<code>{ age: { \$ne: 25 } }</code>	Podudara dokumente gdje vrijednost ključa <code>key</code> nije jednaka vrijednosti <code>value</code> .
\$gt	<code>{ key: { \$gt: value } }</code>	<code>{ age: { \$gt: 25 } }</code>	Podudara dokumente gdje je vrijednost ključa <code>key</code> veća od vrijednosti <code>value</code> .
\$gte	<code>{ key: { \$gte: value } }</code>	<code>{ age: { \$gte: 25 } }</code>	Podudara dokumente gdje je vrijednost ključa <code>key</code> veća ili jednaka od vrijednosti <code>value</code> .
\$lt	<code>{ key: { \$lt: value } }</code>	<code>{ age: { \$lt: 25 } }</code>	Podudara dokumente gdje je vrijednost ključa <code>key</code> manja od vrijednosti <code>value</code> .
\$lte	<code>{ key: { \$lte: value } }</code>	<code>{ age: { \$lte: 25 } }</code>	Podudara dokumente gdje je vrijednost ključa <code>key</code> manja ili jednaka vrijednosti <code>value</code> .
\$in	<code>{ key: { \$in: [value1, value2] } }</code>	<code>{ age: { \$in: [25, 30, 35] } }</code>	Podudara dokumente gdje je vrijednost ključa <code>key</code> unutar danog polja s vrijednostima.
\$nin	<code>{ key: { \$nin: [value1, value2] } }</code>	<code>{ age: { \$nin: [25, 30, 35] } }</code>	Podudara dokumente gdje vrijednost ključa <code>key</code> nije unutar danog polja s vrijednostima.

5.3.3 Logički operatori (eng. Logical operators)

Logical operator	Sintaksa	Primjer	Objašnjenje
\$and	<code>{ \$and: [{ condition1 }, { condition2 }] }</code>	<code>{ \$and: [{ age: { \$gt: 20 } }, { age: { \$lt: 30 } }] }</code>	Spaja više uvjeta, samo dokumenti koji su istiniti za sve uvjete će bit vraćeni.
\$or	<code>{ \$or: [{ condition1 }, { condition2 }] }</code>	<code>{ \$or: [{ age: { \$lt: 20 } }, { age: { \$gt: 30 } }] }</code>	Spaja više uvjeta, dokumenti koji su istiniti za barem jedan uvjet će bit vraćeni.

Logi cal ope rat or	Sintaksa	Primjer	Objašnjenje
\$not	{ key: { \$not: { condition } } }	{ age: { \$not: { \$gte: 30 } } }	Negira uvjet, vraća samo one dokumente za koje uvjet ne vrijedi.
\$nor	{ \$nor: [{ condition1 }, { condition2 }] }	{ \$nor: [{ age: { \$lt: 20 } }, { age: { \$gt: 30 } }] }	Spaja više uvjeta, vraća samo one dokumente gdje koji ne zadovoljavaju niti jedan.
\$exists	{ key: { \$exists: boolean } }	{ age: { \$exists: true } }	Podudara dokumente gdje specificirani ključ key postoji odnosno ne postoji boolean
\$type	{ key: { \$type: value } }	{ age: { \$type: "int" } }	Podudara dokumente gdje je specificirani ključ key određenog tipa podataka value

Samostalni zadatak za Vježbu 5

Nadogradnja pizzerija aplikacije:

Prvi dio samostalnog zadatka odnosi se na nadogradnju postojeće aplikacije. Potrebno je nadograditi Vue.js *frontend* iz skripte WA3. Početna stranica mora prikazivati sve dostupne pizze, uključujući sliku, naziv, cijenu i sastojke. **(ako niste riješili zadaću iz WA3 - potrebno ju je riješiti kao preduvjet za ovu zadaću!).**

Implementirajte sljedeće funkcionalnosti na *backendu*:

- Implementirajte GET `/pizze` endpoint koji će vraćati sve dostupne pizze iz MongoDB baze podataka. Dodajte Mongo indeks za dohvaćanje pizza prema nazivu.
- U MongoDB, nadogradite kolekciju `pizze` s novim poljima: `slika_url`, `sastojci` i `cijene`, po uzoru na WA3 skriptu.
- Implementirajte POST `/pizze` endpoint koji će dodavati nove pizze u kolekciju (možete pozivati endpoint kroz Postman - ne treba raditi VUE UI za dodavanje pizza)
- Implementirajte validaciju podataka koje korisnik šalje na `/pizze` za prethodni endpoint. Morate provjeriti jesu li sadržani svi i točno navedeni ključevi. Provjerite je li cijena broj i svaki sastojak u sastojcima string.

Dodavanje naručivanja:

Drugi dio samostalnog zadatka odnosi se na dodavanje mogućnosti naručivanja pizza. Potrebno je definirati novu kolekciju `narudzbe` u MongoDB bazi podataka. Kolekcija mora sadržavati sljedeće ključeve:

- `ime` - ime osobe koja naručuje
- `adresa` - adresa dostave
- `telefon` - broj telefona
- `narucene_pizze` - polje stavki narudžbe (naručene pizze):
Svaka stavka mora sadržavati sljedeće ključeve:
 - `naziv` - naziv pizze koja se naručuje
 - `kolicina` - količina naručene pizze (cijeli broj)
 - `velicina` - naručena veličina pizze (`'mala'`, `'srednja'`, `'jumbo'`)
- `ukupna_cijena` - ukupna cijena narudžbe (računa se na poslužitelju, **ne šalje klijent**)

Implementirajte sljedeće funkcionalnosti:

- Implementirajte POST `/narudzba` endpoint koji će dodavati nove narudžbe u kolekciju `narudzbe`.
- Implementirajte validaciju podataka koje korisnik šalje na `/narudzba` za prethodni endpoint. Morate provjeriti jesu li sadržani i točno navedeni svi ključevi. Provjerite je li telefon broj ili string koji se sastoji samo od brojeva i je li svaka stavka u polju stavki ispravno definirana (naziv, količina, veličina).
- Na poslužitelju izračunajte vrijednost ključa `ukupna_cijena` na temelju naručenih pizza. Cijenu pizze dobivate dohvaćanjem određene pizze u Mongo kolekciji `pizze`.

Sortiranje i pretraga pizza:

Implementirajte tražilicu na frontendu koje će omogućiti korisnicima da pretražuju pizze prema nazivu i filtriraju ih prema cijeni (npr. sve pizze ispod/iznad određene cijene). Također, omogućite sortiranje pizza prema cijeni (od najjeftinije do najskuplje i obrnuto).

Ovo zahtijeva nadogradnju GET `/pizze` endpointa na backendu kako bi podržavao sljedeće *query* parametre:

- `naziv` - pretraživanje pizza prema nazivu (djelomično podudaranje)

- `cijena_min` - minimalna cijena za filtriranje pizza
- `cijena_max` - maksimalna cijena za filtriranje pizza
- `sort` - sortiranje pizza prema cijeni (`'asc'` za rastuće, `'desc'` za padajuće)
- Implementirajte odgovarajuću logiku na backendu kako biste obradili ove *query* parametre (napomena: korisnik može poslati bilo koji, sve ili nijedan od ovih query parametara).
- Implementirajte odgovarajuću MongoDB logiku za filtriranje i sortiranje podataka na temelju primljenih *query* parametara.